

# 基于深度学习的工业产品表面缺陷检测综述

魏利胜 李 明

(安徽工程大学电气工程学院 安徽芜湖 241000)

**摘 要:**深度学习技术的发展为表面缺陷检测带来了新的可能性。文章论述了监督学习模型方法、无监督学习模型方法以及弱监督学习模型方法下的典型分类,并介绍了每种方法的研究现状。探讨了在工业产品表面缺陷检测中的关键问题和可能的解决方法。对工业产品表面缺陷检测未来的研究方向进行了总结和展望。

**关键词:**深度学习;工业产品表面缺陷检测;图像处理;卷积神经网络

**中图分类号:**TP391.4

**文献标识码:**A

**文章编号:**2095-0438(2024)06-0151-06

基于深度学习的工业产品表面缺陷检测技术主要包括卷积神经网络、循环神经网络和生成对抗网络等。卷积神经网络是一种最为常用和经典的深度学习技术,它能够通过卷积层和池化层等结构,对图像进行特征提取和分类。在工业产品表面缺陷检测中,卷积神经网络已经被广泛应用,并且取得了良好的效果。循环神经网络是一种能够处理序列数据和记忆之前信息的神经网络,它能够对时间序列数据进行建模和处理;生成对抗网络是一种新兴的深度学习技术,它能够通过对抗机制实现生成逼真的数据样本,因此两者都被应用于工业产品表面缺陷检测中。

本文将根据数据标签的不同,从监督方法、无监督方法和弱监督方法三个方面来讨论深度学习在工业产品表面缺陷检测中的应用。并就目前存在的实时问题与小样本问题提出有效的解决方法,同时对未来的发展方向进行展望。通过上述研究,本文旨在为工业产品表面缺陷检测提供新的思路和方法,并为深度学习技术在工业制造领域的应用提供一定的参考和借鉴。

## 一、工业产品表面缺陷检测方法

首先,深度学习是一种基于神经网络的机器学习技术,能够自动学习数据的特征并进行分类、识别等任务。在表面缺陷检测领域,深度学习能够通过学习缺陷图像的特征,准确地检

测出表面缺陷。本节按照数据标签类型的不同,如图1所示,将基于深度学习的工业产品表面缺陷检测总结为监督学习模型方法、无监督学习模型方法以及弱监督学习模型方法,其中,监督方法是目前最常用的。




图1 基于深度学习的工业产品表面缺陷检测方法框架图

(一)监督学习模型方法。监督方法区别于其他方法的特点是需要收集一定数量的表面缺陷图像数据,利用标注好的数据来训练深度神经网络,以识别表面缺陷。目前应用较多的是监督表征学习方法,它需要使用标注的数据,通过学习数据中的特征表示和标签之间的关系,来提高模型的分类或预测性能。在表征学习中,由于网络划分的不同以及对于缺陷检测的侧重点不同,又分为分类、检测和分割网络。

1. 分类网络。分类网络通常采用卷积神经网络(Convolutional Neural Network,CNN)作为基础架构,由若干个卷积层、池化层、全连接层等组成。其主要任务是将输入的表面缺陷图像进行分类,即判断其是否存在缺陷,并对其进行定位。常用的分类网络包括 LeNet<sup>[1]</sup>、AlexNet<sup>[2]</sup>、VGG<sup>[3]</sup>、GoogleNet<sup>[4]</sup>、ResNet<sup>[5]</sup>等,其优点与不足对比如表1所示。

收稿日期:2023-09-28

作者简介:魏利胜(1978—),男,安徽巢湖人,安徽工程大学电气工程学院教授,博士后,研究方向:图像识别与应用、嵌入式仪器仪表及系统研究;李明(2000—),女,安徽铜陵人,安徽工程大学电气工程学院硕士研究生,研究方向:智能检测技术及应用。

基金项目:安徽工程大学研究生教学改革与研究重点项目(2021jyxm001);安徽省教育厅重大项目(KJ2020ZD39)。

表1 典型分类网络优点与不足对比

网络名称	优点	不足
LeNet	采用卷积和池化操作来提取特征,有效减少特征数量和计算量,从而加快模型训练和推理速度	只适用于处理较小的图像,无法适应不同大小的图像
AlexNet	采用Dropout、ReLU等技术,能够有效降低过拟合问题;在多GPU上并行训练	需要大量的计算资源和时间来训练和推理
VGG	采用深度堆积的卷积层和小尺寸的卷积核,提高模型的计算效率和准确性	采用小尺寸的卷积核,其感受野较小,可能导致模型对大尺寸物体的识别出现问题
Google Net	引入了Inception模块,能够在保持模型深度的同时大幅度减少参数量	结构复杂,训练和推理过程的计算量较大
ResNet	引入残差连接解决了深度神经网络训练过程中的梯度消失问题	深度较大的模型训练和推理时间较长,对硬件要求较高

艾婷等<sup>[6]</sup>提出了一种基于改进 AlexNet 的玻壳缺陷检测模型。该模型在 AlexNet 网络模型基础上,引入 1×1 卷积、通道洗牌卷积层和残差网络,优化了模型的结构。通过实验表明:改进后的模型识别准确率达 95.9%。袁泽辉等<sup>[7]</sup>通过加入批量归一化层,改进低层和中间卷积核的构造,优化了 GoogleNet 的构造,提高了卷积神经网络的泛化性和收敛性。改进后验证集的准确率达到 93.32%。Cheon S 等<sup>[8]</sup>提出了一种基于深度学习的 ADC 方法,可以自动对各种类型的晶圆表面损伤进行分类。该模型采用单卷积神经网络(CNN)模型,无需使用额外的特征提取算法即可提取有效特征进行缺陷分类。此外,该方法通过将未见过的类的 CNN 特征与训练类的 CNN 特征进行比较,可以识别训练过程中未看到的缺陷类。在真实数据集上的实验验证了所提 ADC 方法具有较高的缺陷分类性能。

2. 检测网络。检测网络的重点是通过确定缺陷的位置来获取缺陷的具体位置信息和类别信息,目前主要分为两类,一类是两阶段检测算法,代表性算法是 Faster R-CNN(Region-CNN)<sup>[9]</sup>;另一类是单阶段检测算法,代表性算法有 YOLO(You only look once)<sup>[10]</sup>系列网络和 SSD(Single shout multibox detector)<sup>[11]</sup>系列网络。

两阶段检测算法(Faster R-CNN)的特点在于采用 RPN 网络(Region proposal network|区域生成网络)进行候选框生成,减少了后续检测网络的计算量,能够提高检测速度。基本流程是任意尺寸图片经过共享卷积层得到特征图,提取图像特征,根据特征图通过 RPN 网络得到候选区域,再将特征图经过滑动窗口进行滑窗操作,生成一系列候选框,并使用一个分类器来确定这些候选框是否包含物体,对于确定包含物体的候选框,使用 RoI 池化层对其进行特征提取,并将这些特征传递给检测网络,检测网络再对每个候选框进行分类,并计算其边界框偏移量,从而得到最终的检测结果。其训练流程如图 2 所示,该算法需要大量有标签的数据集来进行训练,因此准确率较高,在缺陷检测领域被广泛应用。

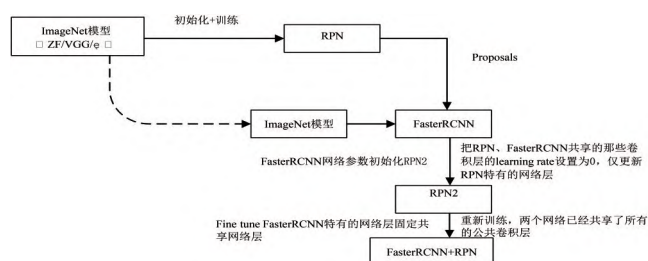


图2 Faster R-CNN 训练流程图

蔡文彪等<sup>[12]</sup>提出一种改进 Faster R-CNN 模型的输电线缺陷检测方法。利用多尺度特征提取区域建议网络,基于 K-均值聚类生成适合于输电线缺陷目标的锚框集,使用 ROIAlign 操作实现特征映射。通过在包含 3672 张输电线缺陷图像的自建数据集上测试表明,该方法有效提升了不同尺度目标以及小尺度目标的缺陷检测性能,mAP (Mean average precision|平均准确率)均值达到 95.57%。Yang 等<sup>[13]</sup>提出了一种基于 Faster RCNN-FPN 的新型特征金字塔网络,它可以跨级别和方向融合特征,以改善小物体检测和定位,并提高物体检测精度。在 463 个轮胎冠气泡缺陷数据集上,mAP 比原始网络增加了 2.08%。

单阶段缺陷检测算法是指只有一个检测阶段,直接使用未标记的数据进行训练和缺陷检测的算法。其中,YOLO 系列算法通过对整个图像进行单次前向传递,直接预测图像中所有物体的位置和类别,YOLO 网络有 5 个组成部分。1)输入层:接受输入图像。2)卷积层:通过一系列卷积操作提取输入图像的特征。3)下采样层:使用池化操作将特征图的分辨率降低,从而减少后续计算量。4)上采样层:使用反卷积操作将特征图的分辨率增加,从而提高检测精度。5)检测层:将特征图转换为目标检测结果。近年来,YOLO 系列算法从 YOLOv1 到 YOLOv8 经过了多次改进与优化,被广泛应用于工业检测的各个领域。与 YOLO 采用单一的检测层来进行目标检测不同,SSD 则采用多个检测层来对不同尺度和大小的物体进行检测,它也由 5 个部分组成。前面 2 个部分与 YOLO 相同,接着是特征图层:使用一系列卷积层将输入图像的特征图转换为一系列不同尺度和大小的特征图。然后是检测层:对每个特征图进行目标检测。SSD 使用卷积层和全连接层将特征图转换为一系列预测框,同时使用卷积层对预测框进行分类和位置回归。最后是非极大值抑制(NMS)层:对多个预测框进行筛选,保留最可信的预测框。YOLO 算法的网络结构图和 SSD 算法的检测框架图分别如图 3、图 4 所示。




图3 YOLO 网络结构图



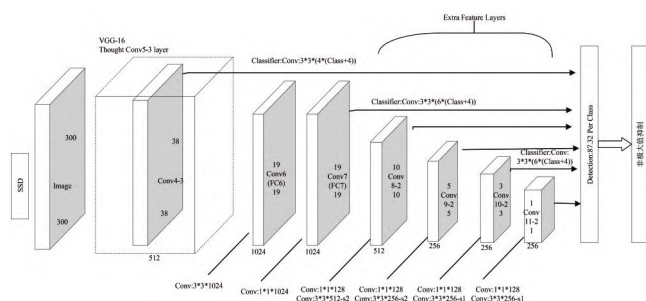


图4 SSD算法检测构架图

阎馨等<sup>[14]</sup>提出了一种钢材表面缺陷检测的改进 SSD 算法。采用 Transformer 多头注意力机制模块代替原 SSD 结构中的 Conv5-1 层,以提高小目标检测的能力;原 SSD 结构中的 Conv7 操作替换为 Involution 算子操作,以减少运算的参数数量。利用 NEU-DET 数据集进行实验,相比改进前平均检测精度提高了 4.5%,检测速度提高了 13.6%。Kou 等<sup>[15]</sup>提出了一种基于 YOLO-V3 的端到端缺陷检测模型。利用无锚特征选择机制为模型训练选择理想的特征尺度,取代基于锚点的结构,缩短计算时间。其次,在模型中引入专门设计的密集卷积块,提取丰富的特征信息。所提出的模型在 GC71-DET 数据集上得到了 3.10% 的 mAP,在 NEU-DET 数据集上得到了 72.2% 的 mAP。

3. 分割网络。表面缺陷检测中的分割网络通常指将待检测的图像分割成若干个子图像, 每个子图像包含一个独立的缺陷或物体, 以便更准确地进行缺陷检测和分类。现阶段, 应用最多的是以全卷积神经网络(Fully convolutional networks, FCN)<sup>[16]</sup>方法为代表的图像语义分割和以 Mask R-CNN<sup>[17]</sup>方法为代表的图像实例分割。

语义分割是指将一张图像中的每个像素都分配到其对应的语义类别上,从而将图像分割成多个语义上具有意义的区域,每个区域被标记为其对应的类别。FCN是一种特殊的卷积神经网络,主要用于图像分割任务。与传统的卷积神经网络相比,FCN将全连接层替换成了卷积层和池化层,从而可以对任意大小的图像进行分割。FCN采用了编码器-解码器的结构,其中编码器部分负责对图像进行特征提取,解码器部分负责将特征图恢复到原始大小并进行分类。在编码器部分,FCN通常采用了预训练的卷积神经网络,如VGG<sup>[3]</sup>、ResNet<sup>[5]</sup>等,用于提取图像的低级和高级特征。在解码器部分,FCN采用了反卷积层或上采样层对特征图进行恢复,并进行像素级别的分类。FCN的输出是一个与输入图像大小相同的分割图像,其中每个像素被标记为其对应的类别。

Jing等<sup>[18]</sup>提出一种极其高效的卷积神经网络 Mobile-Unet 来实现端到端缺陷分割。在 Mobile-Unet 中引入了深度可分离卷积,大大降低了网络的复杂性成本和模型大小。使用 MobileNetV2 特征提取器作为编码器,然后添加五个反卷积层作为解码器。最后,使用 softmax 层生成分割掩码。通过实验表明,该方法的分割精度和检测速度均达到较好水平。杨肖辉等<sup>[19]</sup>提

出基于改进深度学习全卷积网络的缺陷自动检测算法,算法通过改进 FCN 的 VGG 结构、扩展滤波器尺寸、取消全连接层 Dropout 及模型深度,实现 FCN 模型在绝缘子缺陷检测方面的有效改进,实验结果表明,改进模型在较少运行时间增加基础上,有效提高了对绝缘子缺陷检测的性能和对背影的鲁棒性。

图像实例分割是指将一张图像中的每个像素都分配到其所属的实例上,从而将图像分割成多个具有语义和实例信息的区域。Mask R-CNN是在Faster R-CNN的基础上进行改进得到的,可以同时预测物体的类别、边界框和像素级别的掩码。Mask R-CNN的主要思想是在Faster R-CNN的基础上添加一个分支网络,用于预测每个物体的掩码。具体地,Mask R-CNN使用了一个ROI Align层,将每个物体的特征图对齐到固定大小的特征图上,并使用一个卷积神经网络对其进行处理,得到每个物体的掩码。Mask R-CNN的输出包括物体类别、边界框和掩码。其中,掩码是一个与输入图像大小相同的二值图像,每个像素对应于一个物体的掩码。Mask R-CNN可以对不同大小和形状的物体进行实例分割,因此具有较好的通用性和灵活性。

Li 等<sup>[20]</sup>提出一种改进的晶圆缺陷 Mask R-CNN 模型。通过融合残差网络和特征金字塔网络来提高小目标识别能力,在浅层模型中可以充分提取目标特征,从而提高特征提取效率。其次,增加了改进的非极大值抑制(NMS)算法,以解决传统算法带来的错误检测问题;实验结果表明,改进的 Mask R-CNN 模型优于常规模型,对小目标和浅层模型具有更好的识别效果。马志程等<sup>[21]</sup>提出基于改进 Mask R-CNN 的光学元件划痕缺陷检测方法,对 Mask R-CNN 网络模型进行了改进,将原有的 ResNet 更换为 CSPRepResNet,并添加 ESE 注意力机制,提高了特征提取的能力并减少了计算量;其次,利用 K-means 算法重新聚类 anchor boxes 的长宽比例;再次,将目标检测的损失函数由 Cross Entropy 改为梯度均衡化的 Focal Loss,解决了正负样本不平衡问题的同时,更有利于对困难样本的检测,还可以消除离群点的影响。最终实验表明,在推理速度几乎不变的情况下,检测的 mPA 得到了有效提高。

(二)无监督学习模型方法。无监督学习模型在表面缺陷检测任务中的应用越来越受到关注,它使用正常无缺陷样本进行训练,当网络输入的样本与正常样本出现不同结果时,往往就会认为这些样本存在缺陷或者异常。一种常用的无监督学习模型是自编码器(Autoencoder, AE)<sup>[22]</sup>。自编码器是一种神经网络模型,可以将输入数据进行压缩和重构。它由一个编码器和一个解码器组成,其中编码器将输入数据压缩到较低维度的特征向量中,解码器将特征向量解码回原始数据。自编码器可以使用反向传播算法进行训练,将重构误差最小化,从而学习到数据的低维表示。在表面缺陷检测任务中,可以使用自编码器将表面图像压缩到较低维度的特征向量中,然后使用聚类算法对特征向量进行聚类,将相似的特征向量分为一类,从而检

测表面缺陷。除了自编码器,还可以使用其他无监督学习模型,如生成对抗网络(Generative Adversarial Networks,GAN)<sup>[23]</sup>和变分自编码器(Variational Autoencoder,VAE)<sup>[24]</sup>,用于表面缺陷检测任务。这些模型可以学习到数据的潜在分布,从而生成新的样本和检测表面缺陷。

Hu等<sup>[25]</sup>提出了一种基于深度卷积生成对抗网络(Deep Convolution Generative Adversarial Networks,DCGAN)的新型无监督自动检测织物缺陷的方法。该方法通过引入新的编码器组件,扩展了标准DCGAN,该标准由鉴别器和发生器组成。在这个编码器的帮助下,模型可以重建一个给定的查询图像,这样在重建中就不会保留任何缺陷,而只会保留正常的纹理。因此,当从原始图像中减去重建时,可以创建残差图以突出显示潜在的缺陷区域。李阳等<sup>[26]</sup>提出了一种改进生成对抗网络的无监督晶圆表面缺陷检测模型,该模型通过目标图像与重构图像之间的差异来检测缺陷。该方法使用带有两层跳跃连接和记忆模块的编码器-解码器卷积神经网络来搭建生成器,跳跃连接用以捕获多尺度的输入图像特征,记忆模块对潜在特征实施约束,扩大真实缺陷样本与重构样本间的距离。

与传统的监督学习模型相比,无监督学习模型没有标注数据的限制,能够从大量的无标注数据中发现数据的内在结构和规律。但由于只训练了正样本,无监督方法无法确定什么是正确的输出,因此它不能保证对每种类型的缺陷样本(在训练过程中没有出现)都有良好的检测效果。因此,无监督方法的精度仍有很大的提升空间,总的来说,无监督方法对纹理图像的检测效果更好。

(三)弱监督学习模型方法。由于监督方法和无监督方法都有各自的不足,于是有学者结合两者的特点,提出了弱监督学习模型方法。弱监督方法是指在训练时,只使用了部分样本的标注信息或者使用了不完整的标注信息,而不是使用完全标注的数据。在表面缺陷检测中,由于对缺陷的标注比较困难,弱监督学习模型方法可以有效地提高模型的性能和泛化能力。

Louhi等<sup>[27]</sup>提出一种主动弱监督和视觉信息的混凝土结构缺陷检测方法。根据音频和位置信息,主动向用户查询样本对的相似性。这些用于以弱监督方式将特征空间转换为有利的空间,用于聚类缺陷和非缺陷样本,并通过位置信息进行强化。陆顺成等<sup>[28]</sup>提出了一种基于半监督和自注意力机制的深度卷积生成对抗网络(DCGAN)模型用于生成汽车冷凝器外观缺陷图像。在DCGAN中引入自注意力机制,克服卷积网络长距离特征提取的问题,提高了生成样本的质量;通过半监督学习,在无监督判别器中加入监督辅助分类器,并将分类器的交叉熵损失和梯度惩罚加入判别器的损失函数中,提高了模型的收敛速度和稳定性。

可见,在工业产品表面缺陷检测领域,监督方法通常具有较高的准确性和鲁棒性,是目前深度学习方法中最主流的方法,其应用范围越来越广。但是需要大量的标注数据,在实际应用中较为繁琐;同时,产业水平的不断提高,导致不良品样品

的不断减少,对监管方式也有一定的影响。无监督方法和弱监督方法可以减少标注数据的需求,但是目前的精度还不太高,具有广阔的发展前景。

## 二、工业产品检测关键问题与解决方法

(一)实时问题。在实时生产线上进行表面缺陷检测时,往往需要快速、准确地检测出缺陷,并及时作出反应,以保证生产线的正常运行和产品质量。而解决实时问题的常见思路是模型加速,主要从算法、硬件优化两个方面进行。

1. 算法:对于网络算法层面,可以使用轻量级网络来加速模型。常用的轻量级模型有 MobileNet<sup>[29]</sup>, ShuffleNet<sup>[30]</sup>, SqueezeNet<sup>[31]</sup>, EfficientNet<sup>[32]</sup>和 GhostNet<sup>[33]</sup>。此外,蒸馏和修剪也可用于在算法级别加速网络。在计算算法方面,可以优化卷积运算,达到模型加速的目的。典型的算法包括 FFT<sup>[34]</sup>, Winograd<sup>[35]</sup>等。

2. 硬件:为了提高检测速度,可以使用高速相机和高性能计算机等硬件设备,同时采用并行计算和GPU加速技术,近年来在缺陷检测领域还有 FPGA<sup>[36]</sup>, DSP<sup>[37]</sup>的应用,也可以加速模型。

宋敏毓等<sup>[38]</sup>对 YOLOv5 算法进行了改进,建立了 YOLOv5-CS 光纤端面检测模型。在此基础上,提出了一种基于轻量型网络的特征提取方法,并通过深度卷积运算和通道随机混合等方法,降低了模型的规模,增加了特征的信息量。然后引入了卷积注意力机制(Convolutional Block Attention Module,CBAM),并从空间和通道两个维度对特征进行增强,以提高网络的性能;并采用基于数据增广技术的光纤端面数据集。结果显示,相对于 YOLOv5 算法,所提模型的模型容量被压缩了 80%,检测速度被提升了 31.1frame/s,均值平均精度(mAP)被提升了 1.7%,可以更加精确和实时地检测光纤端面缺陷。

(二)小样本问题。表面缺陷检测多应用于工业产品,但是由于工业流程的不断优化,缺陷样本的数量在减少,在数据集较小的情况下,模型很难从有限的数据中学习足够的特征,导致模型的泛化能力较差,小样本问题是表面缺陷检测中的一个重要问题,目前解决方法有以下四种。

1. 数据增强。数据增强是目前最常用的方法,通过对原始数据进行一系列变换,得到更多的数据。比如,可以进行随机旋转、平移、缩放、裁剪等操作。如 Li 等<sup>[39]</sup>对于灌装线中容器密封表面上的缺陷图像进行数据扩展以增加图像数量,并为 K 折交叉验证准备数据集。K 折叠交叉验证方法将扩展的数据集 C 划分为 K 个离散子集。在网络训练期间,选择一个子集作为测试集,而其余(K-1)子集则合并到训练集中。每次训练都会在所选测试集上输出网络模型的分类精度。重复相同的过程 K 次以获得平均精度,即模型的真实精度。

2. 迁移学习。迁移学习是利用已有的模型在目标任务上



进行微调,可以充分利用源领域的知识,提高模型在目标任务上的泛化能力。比如,可以使用预训练的模型进行特征提取,再在目标任务上进行微调。如Wang等<sup>[40]</sup>利用迁移学习,它在COCO对象检测数据集<sup>[41]</sup>上采用预训练模型,并在目标数据集上微调模型。

3.生成对抗网络GAN。GAN可以生成与原始数据相似的样本,可以用来增加数据的数量和多样性,这也是无监督学习的方法之一,用正常样本作训练,生成对抗网络GAN生成一些缺陷样本。如Liu等<sup>[42]</sup>提出一种基于生成对抗网络(GAN)的织物缺陷检测框架,通过训练多阶段GAN来合成新的无缺陷样本中的合理缺陷,对已有的结构性缺陷样本进行动态更新,进而对语义划分网络进行精细调整,从而提高对各种情况下缺陷的识别能力。同样的,弱监督方法也可以很好地解决小样本问题,只需要使用部分样本的标注信息进行训练。

### 三、总结与展望

表面缺陷检测是一个重要而具有挑战性的领域,基于目前的一些问题以及深度学习的快速发展,工业产品表面缺陷检测领域在联邦学习以及监督方法与弱监督方法结合等方向仍具有较大的探索空间。

联邦学习是一种多方参与的分布式学习方法,它可以在不共享数据的情况下,进行模型训练。在工业缺陷检测中,联邦学习可以应用于数据隐私保护、跨域检测、模型优化和非平衡数据处理等方面。不同表面材料之间的缺陷类型和特征可能存在差异,因此在不同的表面材料上进行缺陷检测时可能需要不同的模型。联邦学习可以利用来自不同表面材料的数据进行模型训练,可以实现跨域检测,利用多方数据进行模型训练,可以提高模型的泛化能力和准确率。未来的研究可以探索如何将联邦学习技术与工业缺陷检测相结合,实现更高效、更准确的检测。

监督方法通常需要大量标注数据,但在实际应用中,往往难以获取足够多的标注数据。而弱监督方法则可以利用少量标注数据或不完整的标注数据进行模型训练。将监督方法与弱监督方法结合,可以在保证模型检测性能的同时,降低数据标注的成本。未来的研究可以探索更多的监督方法与弱监督方法结合的方法,以进一步提高工业缺陷检测的性能和效率。

深度学习作为工业产品缺陷检测领域的强大工具正在迅速发展,本文对基于深度学习的工业产品表面缺陷检测的研究现状进行了梳理,分别从监督方法、无监督方法和弱监督方法三个方面介绍了深度学习具体在工业产品表面缺陷检测中的应用。同时,指出工业产品表面缺陷检测领域的一些关键问题,并总结其解决方案。然后,总结了对于工业产品表面缺陷检测结果的一系列性能指标及计算方法。最后,对工业产品表面缺陷检测领域未来的发展方向进行了展望,希望能为今后的

研究提供一些思考。

### 参考文献:

- [1]刘金利,张培玲.改进LeNet-5网络在图像分类中的应用[J].计算机工程与应用,2019,55(15):32-37+95.
- [2]Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems,2012:1097-1105.
- [3]Sengupta A, Ye Y, Wang R, et al. Going deeper in spiking neural networks: VGG and residual architectures[J]. Frontiers in Neuroscience, 2019, 13: 95.
- [4]Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2015: 1-9.
- [5]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2016: 770-778.
- [6]艾婷,史晋芳,向伟.改进的AlexNet模型在玻壳缺陷检测中的应用[J].制造业自动化,2020,42(5):54-56+60.
- [7]袁泽辉,郭慧,周邵萍.基于卷积神经网络的管道表面缺陷识别研究[J].现代电子技术,2020,43(17):47-51.
- [8]Cheon S, Lee H, Kim C O, et al. Convolutional neural network for wafer surface defect classification and the detection of unknown defect class[J]. IEEE Transactions on Semiconductor Manufacturing, 2019, 32(2): 163-170.
- [9]Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6): 1137-1149.
- [10]Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2016: 779-788.
- [11]Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//Computer Vision - ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11 - 14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [12]蔡文彪,李永锋,吴怀诚,等.基于改进Faster RCNN模型的输电线路缺陷检测方法[J].信息技术,2023,47(1):148-153.
- [13]Yang S, Jiao D, Wang T, et al. Tire speckle interference bubble defect detection based on improved faster RCNN-FPN[J]. Sensors, 2022, 22(10): 3907.
- [14]阎馨,杨月川,屠乃威.基于改进SSD的钢材表面缺陷检

测[J]. 现代制造工程,2023,512(5):112-120.

[15]Kou X, Liu S, Cheng K, et al. Development of a YOLO-V3-based model for detecting defects on steel strip surface[J]. Measurement, 2021, 182: 109454.

[16]Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 3431-3440.

[17]He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 2961-2969.

[18]Jing J, Wang Z, Rättsch M, et al. Mobile-Unet: An efficient convolutional neural network for fabric defect detection[J]. Textile Research Journal, 2022, 92(1-2): 30-42.

[19]杨肖辉,绳飞,薛鹏,等.基于深度学习的航拍电网绝缘子缺陷检测[J]. 信息技术,2020,44(4):37-40+45.

[20]Li Y, Wang J. A defect detection method based on improved mask R-CNN for w-afer maps[C]//2021 International Conference on Computer Network, Electronic and Automation (ICCNEA), 2021: 133-137.

[21]马志程,李丹,张宝龙.基于改进Mask R-CNN的光学元件划痕缺陷检测研究[J]. 电子测量与仪器学报,2023,37(4):231-239.

[22]Hinton G E, Zemel R. Autoencoders, minimum description length and Helmholtz free energy[J]. Advances in Neural Information Processing Systems, 1993,6.

[23]Creswell A, White T, Dumoulin V, et al. Generative adversarial networks: An overview[J]. IEEE Signal Processing Magazine, 2018, 35(1): 53-65.

[24]Kusner M J, Paige B, Hernández-Lobato J M. Grammar variational autoencoder[C]//International Conference on Machine Learning, 2017: 1945-1954.

[25]Hu G, Huang J, Wang Q, et al. Unsupervised fabric defect detection based on a deep convolutional generative adversarial network[J]. Textile Research Journal, 2020, 90(3-4): 247-270.

[26]李阳,蒋三新.基于改进生成对抗网络的无监督晶圆缺陷检测[J]. 电子测量技术,2023,46(6):91-99.

[27]Louhi Kasahara J Y, Yamashita A, Asama H. Acoustic inspection of concrete structures using active weak supervision and visual information[J]. Sensors, 2020, 20(3): 629.

[28]陆顺成,姜小峰,石奇.基于改进DCGAN的汽车冷凝器图像生成方法[J]. 微电子学与计算机,2022,39(5):71-77.

[29]Qin Z, Zhang Z, Chen X, et al. Fd-mobilenet: Improved mobilenet with a fast downsampling strategy[C]//2018 25th IEEE International Conference on Image Processing (IC-IP), 2018: 1363-

1367.

[30]Zhang X, Zhou X, Lin M, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 6848-6856.

[31]Hassanpour M, Malek H. Learning document image features with SqueezeNet convolutional neural network[J]. International Journal of Engineering, 2020, 33(7): 1201-1207.

[32]Tan M, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks[C]//International Conference on Machine Learning. PMLR, 2019: 6105-6114.

[33]Han K, Wang Y, Tian Q, et al. Ghostnet: More features from cheap operations[C]//Proceedings of the IEEE/CV-F Conference on Computer Vision and Pattern Recognition, 2020: 1580-1589.

[34]Cochran W T, Cooley J W, Favon D L, et al. What is the fast Fourier transform[J]. Proceedings of the IEEE, 1967, 55(10): 1664-1674.

[35]Fernandez-Marques J, Whatmough P, Mundy A, et al. Searching for winograd-aware quantized networks[J]. Proceedings of Machine Learning and Systems, 2020, 2: 14-29.

[36]Ling C, Jianqiang G, Xiaorong G, et al. Research on rail defect detection system based on FPGA[C]//2016 IEEE Far East NDT New Technology & Application Forum (FENDT). IEEE, 2016: 195-200.

[37]Gao Y, Lin J, Xie J, et al. A real-time defect detection method for digital signal processing of industrial inspection applications[J]. IEEE Transactions on Industrial Informatics, 2020, 17(5): 3450-3459.

[38]宋敏毓,陈力荣,梁建安,等.轻量化改进网络的实时光纤端面缺陷检测模型[J]. 激光与光电子学进展, 2022, 59(24): 201-211.

[39]Li Y, Huang H, Xie Q, et al. Research on a surface defect detection algorithm based on MobileNet-SSD[J]. Applied Sciences, 2018, 8(9): 1678.

[40]Wang C, Xiao Z. Potato surface defect detection based on deep transfer learning[J]. Agriculture, 2021, 11(9): 863.

[41]Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]//Computer Vision - ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V 13. Springer International Publishing, 2014: 740-755.

[42]Liu J, Wang C, Su H, et al. Multistage GAN for fabric defect detection[J]. IEEE Transactions on Image Processing, 2019, 29: 3388-3400.

[责任编辑 郑丽娟]