



计算机应用  
*Journal of Computer Applications*  
ISSN 1001-9081, CN 51-1307/TP

## 《计算机应用》网络首发论文

题目：工业缺陷检测无监督深度学习方法综述  
作者：王文鹏，秦寅畅，师文轩  
收稿日期：2024-06-05  
网络首发日期：2024-09-12  
引用格式：王文鹏，秦寅畅，师文轩. 工业缺陷检测无监督深度学习方法综述[J/OL]. 计算机应用. <https://link.cnki.net/urlid/51.1307.TP.20240911.1259.002>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

# 工业缺陷检测无监督深度学习方法综述

王文鹏, 秦寅畅, 师文轩\*

(南开大学 软件学院, 天津 300350)

(\*通信作者电子邮箱 shiwx@nankai.edu.cn)

**摘要:** 工业缺陷检测在保障产品质量、提高企业竞争力方面具有极其重要的作用。传统的缺陷检测方法依赖于人工检查, 成本高且效率低下, 难以满足大规模的质量检验需求。近年来, 基于视觉的工业缺陷检测技术取得了显著的进步, 已成为产品外观质量检验的一种高效解决方案。但在许多实际工业场景中, 获取大量带有标签的数据非常困难, 且对产品检测的人工成本和实时性均有所要求, 因此, 无监督学习逐渐成为研究的热点。针对该领域任务构建、现行技术、评估标准以及不同方法之间的共性和差异, 对相关工作进行综述。首先, 明确了工业缺陷问题的定义, 并从数据难点和任务挑战等多个角度分析了问题的难点; 其次, 重点介绍了基于无监督深度学习的工业缺陷检测主流方法, 并进行了详细的归纳与分析; 再次, 介绍了常用的公开数据集与评价指标; 最后, 对工业缺陷检测领域将来的工作进行了展望。

**关键词:** 缺陷检测; 异常检测; 计算机视觉; 工业视觉; 深度学习; 无监督学习

**中图分类号:** TP391.41

**文献标志码:** A

## Review of unsupervised deep learning methods for industrial defect detection

WANG Wenpeng, QIN Yinchang, SHI Wenxuan\*

(College of Software, Nankai University, Tianjin 300350, China)

**Abstract:** Industrial defect detection plays a crucial role in ensuring product quality and enhancing enterprise competitiveness. Traditional defect detection methods rely on manual inspection, which is costly and inefficient, making it difficult to meet the demands of large-scale quality inspection. In recent years, vision-based industrial defect detection technology has made significant progress and has become an efficient solution for product appearance quality inspection. However, in many practical industrial scenarios, it is challenging to obtain large amounts of labeled data, and there are requirements for both the labor cost and real-time performance of product detection. Therefore, unsupervised learning has gradually become a research hotspot. This paper reviews related work on task construction, current technologies, evaluation standards, and the commonalities and differences between various methods in this field. Firstly, the definition of industrial defect problems is clarified, and the difficulties of the problem are analyzed from multiple perspectives, such as data challenges and task difficulties. Secondly, the mainstream methods of industrial defect detection based on unsupervised deep learning are introduced, and detailed summaries and analyses are provided. Thirdly, commonly used public datasets and evaluation metrics are introduced. Finally, future work in the field of industrial defect detection is discussed.

**Keywords:** Defect Detection; Anomaly Detection; Computer Vision; Industrial Vision; Deep Learning; Unsupervised Learning

### 0 引言

在现代工业生产中, 产品质量直接影响企业的生存和发展。为了确保质量, 缺陷检测至关重要。传统的人工视觉检查效率低且易受人为因素影响, 无法满足现代需求<sup>[1]</sup>, 因此研究高效、准确的自动缺陷检测方法非常重要。近年来, 深度学习在图像和语音识别等领域取得显著成果, 通过模拟人脑神经网络, 能自动学习和提取高层特征, 解决复杂问题。这

些技术的应用不仅提高了产品合格率、降低了成本, 还提高了检测精度和速度, 为操作人员提供了简便和安全的环境。因此, 工业缺陷检测已成为智能制造和自动化生产线的关键技术, 广泛应用于无人质检、智能监控、生产管理和质量追溯等领域。

然而, 工业缺陷检测面临样本稀缺、缺陷不明显、形状多样和种类繁多等挑战, 传统方法难以同时达到高精度和高速度<sup>[2]</sup>。工业缺陷检测侧重于像素级别的精确识别和定位, 而不仅是判断整个图像是否异常。由于缺陷的微小和复杂性,

收稿日期: 2024-06-05; 修回日期: 2024-08-26; 录用日期: 2024-08-28。

作者简介: 王文鹏(2001—), 男, 山东德州人, 硕士研究生, CCF 会员, 主要研究方向: 大数据分析与应用; 秦寅畅(2000—), 男, 湖南长沙人, 硕士研究生, CCF 会员, 主要研究方向: 大数据分析与应用; 师文轩(1977—), 男, 河北廊坊, 副教授, 博士, CCF 会员, 主要研究方向: 机器学习、区块链。

传统方法难以满足要求。深度学习能够更好地理解和提取缺陷特征,提高检测系统的性能和适应性,为工业缺陷检测提供了新方法。

工业生产过程复杂,缺陷受多种因素影响,模式多变且新缺陷类型不断出现,传统方法难以适应。无监督学习在工业缺陷检测中应用广泛,因为它不依赖大量标注数据,能自动学习潜在特征和模式。由于获取大量缺陷标注数据代价高且耗时,无监督学习通过学习正常样本建立表征,从而检测异常样本,并可用于新产品缺陷检测,提升系统灵活性和适应性。因此,无监督学习在工业缺陷检测领域具有广阔前景,逐渐成为研究热点。

鉴于此,本文首先探讨工业缺陷检测的研究背景,明确问题定义,并分析数据难点和任务挑战。接着,综述了当前研究现状。随后,重点介绍了近年来基于无监督深度学习的工业缺陷检测方法,分为基于图像相似度和基于特征相似度两类,并进行了详细分析。此外,介绍了常用的公开数据集与评价指标,为研究提供标准化评估体系。最后,本文总结了当前研究的局限性,并展望了未来的发展趋势和潜在研究方向。

## 1 研究背景

### 1.1 问题定义

工业缺陷检测是一种确保产品质量和安全的技术。它使用机器视觉、传感器技术和自动化软件等方法,检测产品表面或内部的缺陷,如裂纹、孔洞、异物和变形,以便及时修复或剔除不合格品。

缺陷是产品表面的物理瑕疵,如裂纹、划痕和凹陷<sup>[3]</sup>。异常是图像中不符合正常模式的部分<sup>[4]</sup>,包括颜色、纹理或形状的异常变化。缺陷是具体的物理问题,而异常是更广泛的概念,涵盖任何偏离正常情况的图像特征。




图1 异常类别

Fig. 1 Types of Anomalies

在工业缺陷检测中,缺陷通常被视为异常。如图1所示,工业场景中的异常分为纹理异常和功能性异常<sup>[5]</sup>。纹理异常涉及产品表面的纹理变化,如裂纹和划痕。功能性异常则可能不涉及明显的纹理变化,但包含重要的语义信息,如组件缺失、装配不正确或部件存在结构性问题。

在深度学习中,无监督方法只使用正常图像进行训练,无须缺陷样本。在工业场景中,正常图像远多于异常样本,无监督方法简化了数据收集过程,减少了人工标注需求,提高了检测效率。此外,无监督方法不依赖特定缺陷标注,能适应新的检测任务和环境变化。

根据输出结果粒度的不同<sup>[1]</sup>,工业缺陷检测包括分类和定位。分类是在图像层面区分有缺陷和无缺陷图像,而定位(异常分割)用于产生像素级别的异常位置结果。

除缺陷检测外,还有图像分割、图像显著性检测、异常检测和新颖性检测等相关术语。图像分割是广泛概念,缺陷定位相当于无监督图像分割,但主要关注带有语义信息的特定对象。图像显著性检测是找到图像中重要对象的显著区域,但有些异常可能不显著。异常检测和缺陷检测在工业场景中几乎等同。新颖性检测则从统计角度识别数据集中的异常值,而缺陷检测专注于识别和分类具体的物理缺陷。

### 1.2 问题难点

本文从数据难点与任务挑战两个角度进行分析。

#### 1.2.1 数据难点

1) 训练样本分布不平衡。在缺陷检测领域,训练样本的不平衡分布是一个普遍问题,表现为图像前景与背景、缺陷有无、不同缺陷类型及缺陷尺寸的不平衡,以及缺陷特征和现实条件的不确定性。由于缺陷样本相对较少,无监督学习使用无缺陷样本进行训练,但其分布平衡性对模型判断异常位置的能力有显著影响。如果训练集中遗漏某些正常样本,模型可能会误判这些为异常。

2) 未知性与主观性。因某些数据特征难以识别,缺陷模式不可预知,尤其在长尾分布的情况下,收集平衡标签困难,限制了传统方法识别新型缺陷的能力。此外,缺陷定义需结合特定场景,增加了数据标注的难度。

3) 噪声。在复杂的工业场景中,正常数据中可能存在污染或数据噪声。成像条件的变化,如照明、视角、规模、阴影、模糊等,可能导致训练样本出现不应视为异常的显著差异。

4) 可视性低。缺陷通常占高分辨率图像的小部分区域,对比度低,显著性不足,且信噪比低,成像噪声干扰检测。因此,与一般异常检测相比,工业缺陷检测中正负样本差异非常微小<sup>[6]</sup>。

5) 异质性异常。异常是不规则的,一个异常类别可能与另一个异常类别表现出完全不同的异常特征。传统检测方法



局限于识别特定缺陷,易忽视其他类型的缺陷。现代检测方法必须能够识别各种不同外观的缺陷,以确保全面性<sup>[7-8]</sup>。

6) 多尺度异常。在真实的工业场景中,小范围异常如裂纹可能仅占几个像素,易被忽视;大范围异常也常见。

7) 背景复杂。传统方法基于简单背景设计,但现在的产品结构和纹理复杂多变。高分辨率图像融合多种组件,成像环境不稳定性导致同类产品在不同条件下拍摄的图像差异明显,多视角巡检增加了识别难度。

### 1.2.2 任务挑战

1) 精细边界问题。模型的决策边界应等于理想的分布边界。然而,由于像素级监督标签稀缺,模型决策边界与理想分布边界不一致,导致异常轮廓定位不准确。

2) 异常检测的召回率较低。异常事件稀有且多样,全面识别异常困难。现行方法高假阳性率,降低假阳性率并提升召回率是当前重要挑战,尤其考虑到未及时发现异常可能带来的重大损失。

3) 在抗噪声异常检测方面,无监督方法不能充分利用标记数据,且存在大量含有异常的未标记数据。抗噪声模型能利用这些数据提高检测准确性,但噪声数据量和分布不规则是主要挑战。

4) 模型训练时间和计算资源限制。深度学习模型通常需要较长的训练时间和大量的计算资源,这在资源有限的情况下可能成为制约因素。

## 1.3 研究现状

总的来说,工业缺陷检测无监督深度学习方法的综述的研究历程可以分为以下几个阶段:

首先是传统图像处理阶段:在深度学习兴起前,主要依赖边缘检测、形态学运算、特征提取等传统方法。这些方法对简单场景和规则缺陷有效,但在复杂场景下性能有限<sup>[9]</sup>。

随着深度学习技术的发展,有监督深度学习方法开始应用于工业缺陷检测领域,一般称这个阶段为有监督深度学习阶段:卷积神经网络(Convolutional Neural Networks, CNN)成为主要工具,能够在大量标注数据上实现高检测准确率。然而,这些方法需要大量标注数据,而工业缺陷数据难以获取且成本高昂<sup>[10]</sup>。

而为了解决标注数据不足的问题,研究人员开始使用无监督方法,如基于重构误差或特征学习的方法,学习正常样本的分布来检测异常样本<sup>[11]</sup>。

随着研究的深入,方法逐渐从简单的重构误差模型发展到复杂的模型,如深度聚类网络和域对抗网络,通过学习数据内在结构和分布,提高检测性能。

然而,在无监督学习过程中,噪声问题逐渐成为一个重要挑战。尽管无监督方法可以减少对大量标注数据的依赖,但在实际应用中,往往会遇到大量含有异常的未标记数据。

噪声可能来源于误标的数据或未标记的异常,这些噪声数据在数据空间中的分布可能极不规则。能够抵御噪声的模型可以利用这些未标记数据来提高检测的准确性。例如,Chung等<sup>[12]</sup>通过知识蒸馏抑制内容转换,以避免噪声及其他因素的影响;Tan等<sup>[13]</sup>采用新颖的信任区域记忆更新方案,使噪声远离记忆槽;Kimura等<sup>[14]</sup>则利用对抗训练中判别器的类激活图,抑制图像背景中的噪声和干扰。

最后在无监督深度学习研究方法深化期阶段,研究关注模型的可解释性和实用性,引入注意力机制和图卷积网络,结合迁移学习和领域自适应技术,提高模型的泛化能力和适应性。

目前,国内外的综述文献主要集中在广义的异常检测领域,这些研究试图覆盖图像、视频、表格和序列等多种数据类型。例如,文献[2,15]对深度学习在异常检测中的应用进行了广泛的总结,但并未专门针对工业领域的挑战进行深入探讨。文献[7,8]虽然以工业生产为背景,但主要聚焦于传统方法和系统控制技术。文献[16]对基于深度学习的表面缺陷检测方法进行了系统的综述,但重点在于有监督学习范式。Ehret等的工作<sup>[17]</sup>回顾了截至2018年的经典方法,因而并未包含近期基于深度学习的新兴解决方案。Yang等<sup>[18]</sup>简要概述了基于深度学习的传统视觉异常检测和分割技术。Ruff等<sup>[19]</sup>对传统“浅层”方法和新兴“深层”方法之间的联系进行了全面的回顾。Mohammadi等<sup>[20]</sup>对基于图像和视频的深度学习异常检测方法进行了概述和分类,将其分为自监督学习、生成网络和异常生成三个类别。Saberironaghi等<sup>[21]</sup>,从监督、半监督和无监督三个角度讨论了基于深度学习的工业产品表面缺陷检测,并讨论了X射线图像缺陷检测方法的研究现状。Cui等<sup>[22]</sup>对最近提出的用于视觉工业异常检测的无监督算法进行了全面概述,涵盖了五个类别,详细描述了其创新点和框架。Dutta等<sup>[23]</sup>研究了基于深度学习的关键无监督方法用于三个公开可用的基准标记工业缺陷检测数据集。

尽管已有大量研究为异常检测提供了重要见解,但工业缺陷检测中的无监督深度学习方法尚缺乏全面的综述。近期,无监督和半监督学习在该领域取得了显著进展,但相关文献尚未系统总结这些新方法。因此,本综述重点关注工业缺陷检测领域的无监督深度学习方法,以为研究人员和实践者提供参考。

## 2 检测方法

在工业缺陷检测中,无监督深度学习方法相比有监督方法,不依赖缺陷样本的标注,能够探测未知类型的缺陷。这些方法主要通过学习正常样本的分布模式来检测缺陷。如表1所示,根据数据处理与比较的维度不同,无监督方法可以分为基于图像相似度和基于特征相似度的方法。

表1 工业缺陷检测无监督深度学习方法

Tab. 1 Unsupervised Deep Learning Methods for Industrial Defect Detection

级别	类别	方法
像素	基于 AE 方法	多尺度, 特征聚类, 记忆库, 自监督, 多解码器
	基于 VAE 方法	限制潜在空间, 注意力机制, 高斯混合模型, 多解码器
	基于 GAN 方法	结合 AE/VAE
	基于 Transformer 方法	Vision Transformer
特征	深度一类分类	构造分类面
	孪生网络架构	映射到特定特征空间比较
	深度统计模型	多变量高斯分布建模
	流模型	正则化流
	教师-学生架构	知识蒸馏、反向蒸馏

## 2.1 基于图像相似度的方法

基于图像相似度的方法在像素层面比较图像, 核心是构建一个与输入样本相似的正常图像, 使差异仅在缺陷区域显现。

具体来说, 当输入异常图像时, 模型无法正确重建异常区域。通过比较重建图像和输入图像的差异, 可以估计缺陷存在的概率, 并通过设定阈值实现缺陷区域的精确分割。

此类方法常使用自编码模型与生成式模型, 如自编码器 (Auto Encoder, AE)<sup>[24]</sup>、变分自编码器 (Variational Auto Encoder, VAE)<sup>[25]</sup>、生成对抗模型 (Generative Adversarial Networks, GAN)<sup>[26]</sup>等。原本在自然语言处理领域取得巨大成功的 Transformer<sup>[27]</sup>模型, 也逐渐被应用于工业缺陷检测领域。

根据模型主体架构的不同, 此类方法分为基于 AE、VAE、GAN 和 Transformer 的方法。

### 2.1.1 基于 AE 的方法

AE 旨在学习低维特征表示空间, 并在其上重建数据实例。如图 2 所示, AE 由编码器和解码器组成。编码器将原始数据映射到低维特征空间 (潜在空间), 解码器则尝试从低维空间恢复数据, 保留重建数据时的重要信息。




图2 自编码器架构

Fig. 2 Architecture of Auto Encoder

Kang 等<sup>[28]</sup>使用 Faster R-CNN 定位接触网组件, 然后通过深度材料分类器和深度去噪自编码器确定分类和异常得分。Youkachen 等<sup>[29]</sup>使用卷积自编码器进行工业图像重建, 通过锐化过程增强图像差异, 生成分割结果。

1) 多尺度。使用多尺度特征信息可以为图像的重建提供不同粒度的上下文信息, 使重建图像更准确清晰。Mei 等<sup>[30]</sup>在不同的高斯金字塔层级上重建图像块, 并从不同的分辨率

通道中综合检测结果, 保留图像的结构信息并通过引入噪声来增强模型的泛化能力。Yang H 等<sup>[31]</sup>则将编码器提取的多尺度特征图输入到多个解码器中, 重建不同尺度的纹理背景图像, 并将多个生成的残差图像融合成一个结果图像。不同于前两者, Yang J 等<sup>[32]</sup>则在图像重建前融合多尺度特征信息, 设计深度卷积自编码器, 对多尺度区域特征进行压缩和重建, 形成密集多尺度区域特征表示, 再进行图像重建。

2) 记忆库。记忆库的核心思想是学习和存储正常数据特征, 用这些特征重建新输入数据。Gong 等<sup>[33]</sup>利用外部记忆模块记录正常数据模式, 并用其重建输入数据。Yang 等<sup>[34]</sup>使用多个编码器和记忆模块处理不同分辨率图像特征, 捕捉多尺度正常模式, 并用注意力融合器加以整合。Park 等<sup>[35]</sup>引入特征紧凑性和分离性损失, 增强记忆项和从正常数据中深度学习特征的判别力。Wang 等<sup>[36]</sup>通过基于注意力的寻址操作从记忆库获取与输入特征相关的表示, 并用估计网络模块通过最大化潜在表示的似然刻画正常数据概率。Tan 等<sup>[37]</sup>使用记忆增强的自编码器, 配合稀疏记忆寻址方案, 避免自编码器过度泛化, 并采用信任区域记忆更新方案, 使噪声远离记忆槽。Yao 等<sup>[38]</sup>提出了记忆特征模块, 利用对比学习对编码后特征进行判别性约束, 使正常特征和异常特征在隐空间中有较大距离。Xing 等<sup>[39]</sup>提出分区记忆库模块, 引入多个局部单元分别存储不同区域正常特征。Liu 等<sup>[40]</sup>通过金字塔变形模块与信息压缩模块, 将变形与原型嵌入解耦, 通过估计从重建参考到原始输入的多尺度变形场检测异常。

3) 自监督学习 (Self-Supervised Learning, SSL)。SSL 不依赖标记数据集, 而是通过输入数据本身学习数据表示。在异常检测中, 代理任务是常见的 SSL 方法, 通过设计与主任务相关但不同的任务训练模型, 如图像修复、相对位置预测和属性恢复等。

Li 等<sup>[41]</sup>对图像进行超像素分割, 随机遮挡一些超像素块, 训练图像修复网络<sup>[42]</sup>恢复被遮挡区域。Huang 等<sup>[43]</sup>提出渐进式遮罩细化方法, 逐步揭示正常区域, 最终定位异常区域。

Ye 等<sup>[44]</sup>擦除原始数据中选定的属性,训练网络恢复这些属性,迫使网络学习语义特征嵌入。

在正常图像上添加人工合成缺陷,训练模型恢复图像也是常见的自监督学习方法。Collin 等<sup>[45]</sup>提出 Stain 噪声模型,在图像上添加不规则且颜色和大小随机的椭圆形结构,使用类似 U-Net<sup>[46]</sup>的自编码器结构进行恢复。Zavrtanik 等<sup>[47]</sup>在无异常图像上生成合成异常样本,提供像素级异常标签,用于训练模型的判别能力。Song 等<sup>[48]</sup>通过随机高斯采样生成的异常掩码生成或转换异常图像,引入异常信息,使模型学习异常特征表示。Bauer 等<sup>[49]</sup>对随机图像块进行弹性变形或高斯扰动,同时生成掩码标记被修改区域,他使用两种训练目标,使模型准确重建正常区域的同时放大异常区域重建误差。

Zavrtanik 等<sup>[50]</sup>将输入图像投影到潜在空间,通过空间内采样替换特征向量,生成近真实分布的异常。Xing 等<sup>[51]</sup>在正常样本上生成伪造异常样本,利用自监督模块提取的特征作为先验知识,指导分割模块定位异常区域。Mousakhan 等<sup>[52]</sup>框架将目标图像设置为输入图像,引导修改版的 U-Net 网络的去噪过程,从而实现无缺陷的重建。他引入了一种域适应方法,提高了特征层面比较的有效性。

4) 多解码器。在 AE 中,可以用多个解码器重建数据的不同部分,提高模型性能和灵活性。Song 等<sup>[48]</sup>使用两个独立解码器将异常图像分解为纹理背景图像和异常图像,通过强制有缺陷和无缺陷图像的纹理特征共享一个分布,放大缺陷重建误差。Zavrtanik 等<sup>[50]</sup>使用两个处理不同外观子空间的解码器并行解码,高保真重建任意自然图像,并仅重建对象的正常局部外观。

5) 其他。AE 的图像重建是有损的,无法保证与输入图像完全一致。Chung 等<sup>[53]</sup>通过知识蒸馏和异常暴露正则化从 AE 中学习风格转换,同时抑制内容转换,避免噪声及其他因素影响。Yang 等<sup>[31]</sup>则使用深度嵌入聚类增强编码图中特征的判别能力,使相似特征聚集,增强潜在空间编码特征的可区分性。

### 2.1.2 基于 VAE 的方法

VAE 为潜在空间中的正常样本引入先验分布,其编码器输出的是输入数据的概率分布。如图 3 所示,VAE 和 AE 的区别在于额外的正则化损失,用来评估估计分布和先验分布之间的差异,如 Kullback-Leibler 散度损失。




图3 变分自编码器架构

Fig. 3 Architecture of Variational Auto Encoder

最初,Dehaene 等<sup>[54]</sup>提出能量函数衡量数据点与正常数据流形的距离,通过梯度下降优化能量函数,迭代调整数据点,使其逼近正常数据分布,帮助定位异常部分。

学习或限制潜在向量分布可提升模型区分能力。Abati 等<sup>[55]</sup>设计深度自编码器,配备自回归密度估计器,通过最大似然原理学习正常样本潜在向量分布。Xie 等<sup>[56]</sup>使用变分自编码器作为生成模型,通过记忆模块限制潜在空间向量,增加异常样本重建误差。

注意力机制允许模型集中关注重要部分。Liu 等<sup>[57]</sup>提出生成 VAE 视觉解释新技术,使用类似梯度加权类激活映射<sup>[58]</sup>的方法,直接利用 VAE 潜在空间计算梯度并生成注意力图。

此外,Zhou 等<sup>[59]</sup>使用高斯混合模型对 VAE 提取的特征进行密度估计,根据重建误差和密度估计结果输出缺陷密度图。Xie 等<sup>[56]</sup>使用多头解码器,并通过结合 GAN 限制生成样本分布质量,使生成分布接近真实正常数据分布。

### 2.1.3 基于 GAN 的方法

GAN 由生成器和判别器组成。生成器从随机噪声分布中学习生成数据,模仿真实数据分布。判别器则判断数据的真实性。两个网络在训练中相互竞争,从而提高彼此的性能。

最初,Schlegl 等<sup>[60]</sup>随机初始化潜在变量,通过反向传播和梯度下降更新潜在变量,重构与输入图像相似的正常图像,从而将样本映射到潜在空间。由于 GAN 只学习正常样本分布,重构图像不含异常特征,其与输入图像的差异可用于定位异常。Murase 等<sup>[61]</sup>在潜变量中引入异常状态,使生成器产生伪异常数据和假正常数据,判别器则训练区分它们。

#### 1) 与 AE 结合。

将 GAN 与 AE/VAE 结合可以有效增强 GAN 模型的性能。根据其增强方式,可以将模型分为两类:增强模型结构与限制潜在空间,如图 4 所示。

#### ① 增强模型结构。

GAN 中的生成器可作为 AE 或 VAE 的解码器,也可引入编码器引导生成器生成图像。Zenati 等<sup>[62]</sup>将生成器结构倒置为编码器,训练时根据重建损失和判别损失共同约束进行端到端训练。Sabokrou 等<sup>[63]</sup>使用重构网络重构输入图像,使其更接近目标类概念,并使用判别网络学习目标类分布特征。Schlegl 等<sup>[64]</sup>先通过 Wasserstein GAN 训练学习生成器和判别器参数,再固定二者的参数,只调整编码器参数,利用判别器输出指导编码器训练,使重建图像更接近真实分布。



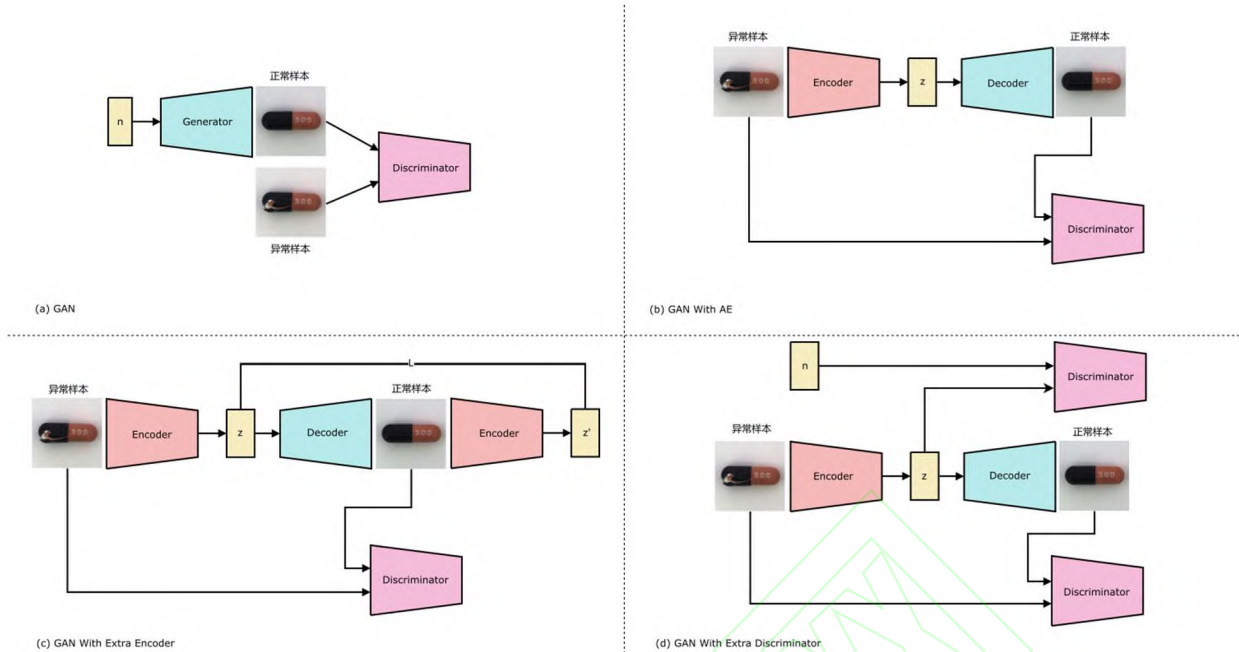


图4 基于生成对抗网络的方法架构

Fig. 4 Architecture of Methods Based on Generative Adversarial Networks

Baur 等<sup>[65]</sup>使用对抗网络训练解码器部分, 避免 VAE 的记忆问题, 提高重建样本真实性。Akçay 等<sup>[66]</sup>在编码器和解码器之间引入跳跃连接, 提高图像重建质量。Yao 等<sup>[38]</sup>提出基于文本元的特征重排方法, 通过匹配正常特征基本微结构抑制缺陷重建。

Zaheer 等<sup>[67]</sup>使用鉴别器区分好与坏的重建质量, 利用训练至不同程度的生成器训练鉴别器, 以检测异常数据重建中的微妙扭曲。Liang 等<sup>[68]</sup>使用多个生成器分别重建不同频率图像信息, 并使用通道选择模块在不同频率编码器间交互, 通过自适应选择不同通道特征增强模型。

模型也可使用自编码器作为判别器。Berthelot 等<sup>[69]</sup>使用自编码器作为判别器, 不直接匹配数据分布, 而是匹配自编码器损失分布。Tang 等<sup>[70]</sup>同样使用自编码器作为判别器, 通过对抗损失、生成器上下文损失和判别器上下文损失优化生成器和判别器参数。Yang 等<sup>[71]</sup>用自编码器判别真实图像和重建图像在像素级别的差异, 通过对抗学习提高重建质量。

## ② 限制潜在空间。

对潜在空间特征施加约束是改进 GAN 的常见方法。模型通过引入编码器提取重建图像特征, 限制其与输入图像特征的距离。Akçay 等<sup>[72]</sup>在引入编码器提取图像特征基础上, 通过另一个编码器将重建图像压缩成低维特征向量, 通过低维特征约束输入和重建图像在潜在空间的距离。Akçay 等<sup>[66]</sup>的判别器兼具特征提取器功能, 计算输入和重建图像的隐层特征表示, 用于判断异常。Komoto 等<sup>[73]</sup>通过引入一致性损失确保图像空间和潜在空间相互映射的一致性。Zhou 等<sup>[74]</sup>引入领域自适应方法训练的结构提取模块, 将结构差异作为缺陷定位判断标准。Hong 等<sup>[75]</sup>在均方误差损失基础上增加正则化项, 最大化正常类潜在向量离散度, 使模型能在任何输入

下生成正常类图像。Venkataramanan 等<sup>[76]</sup>使用注意力扩展损失, 鼓励注意力图覆盖整个正常图像区域, 使网络学习正常图像特征表示。Kimura 等<sup>[14]</sup>利用对抗训练中判别器的类激活图构造掩码, 并用其计算异常分数。

模型也可通过引入判别器限制隐空间分布。Pidhorskyi 等<sup>[77]</sup>在 GAN 基础上引入另一个判别器, 使潜在空间尽可能接近正态分布, 通过评估其内部概率分布检测样本是否异常。Perera 等<sup>[78]</sup>使用判别器强制潜在表示服从均匀分布, 使该空间只能生成给定类别样本。

此外, Hou 等<sup>[79]</sup>引入记忆库模块, 利用多尺度块状内存模块调节模型对正常和异常样本的重建能力。Yang 等<sup>[71]</sup>用基于中心约束的聚类方法学习正常特征分布, 并用自适应阈值检测异常特征, 抑制缺陷重建。

GAN 增强后可用于自监督学习。Salehi 等<sup>[80]</sup>将图像分割成四部分并随机打乱成拼图, 训练网络重建原始图像, 同时添加噪声, 使网络学习更高层次特征。Yan 等<sup>[81]</sup>使用多尺度条纹掩码遮盖部分区域, 用 GAN 重建这些未见区域, 迫使网络学习周围语义特征完成这些区域。

### 2.1.4 基于 Transformer 的方法

Transformer 模型利用自注意力机制和多头注意力并行处理序列, 通过位置编码处理顺序信息, 使用残差连接和层归一化优化训练过程, 在依赖关系复杂的任务中表现出色。

Transformer 模型最初用于 NLP 任务, 现已扩展到计算机视觉领域, 处理图像分类和对象检测等任务。Pirnay 等<sup>[82]</sup>将输入图像分割成大小相等方块, 每块嵌入潜在空间, 加上位置信息形成序列, 从序列中随机选择一个块遮盖, 使用一系列 Transformer 块对序列进行自注意力编码, 利用全局上下

文信息重建被遮盖块。ViT(Vision Transformer)<sup>[83]</sup>将图像分割成小块并转换为补丁嵌入处理图像数据,引入位置嵌入保留空间信息,添加可学习分类嵌入用于图像分类。Mishra 等<sup>[84]</sup>在 ViT 基础上引入高斯近似网络,使用多个高斯分布近似正常数据潜在空间分布。Lee 等<sup>[85]</sup>采用基于 ViT 的模型结构,通过转置卷积层从特征图中重建与原始图像相同大小图像,利用重建误差识别异常区域。De 等<sup>[86]</sup>对输入图像多形状多尺度图像块进行遮盖,在 ViT 自注意力模块中加入掩码组件,使每个图像块只能从周围图像块获取信息,忽略自身潜在异常信息。You 等<sup>[87]</sup>同样应用此思想,提出了邻域掩蔽注意力。Jiang 等<sup>[88]</sup>在无异常样本上应用异常模拟和遮罩策略生成模拟异常,利用 Swin Transformer<sup>[89]</sup>修复被遮罩区域,最后使用基于卷积的 U-Net 网络进行端到端异常检测。

此外, Yao 等<sup>[90]</sup>提出了一个结合了自注意力和记忆注意力机制的 Transformer 框架,增强了模型对历史信息的记忆能力,并引入了归一化流。Zhang 等<sup>[91]</sup>提出了一种基于互注意力的 Transformer 架构,能够捕捉长距离依赖并融合局部和全局特征,从而提高图像异常检测的效果。Xiao 等<sup>[92]</sup>利用空间-光谱双窗口掩码 Transformer 解决了高光谱图像的异常检测问题,充分利用空间和光谱信息提高了检测精度。

## 2.2 基于特征相似度的方法

基于图像相似度的方法因其直观性和可解释性在缺陷检测中受关注。然而,这些方法往往难以实现理想的重建效果,如像素对齐不足和风格变化,这限制了检测性能。此外,像素层面的比较易受噪声影响,降低了鲁棒性。

为克服这些挑战,研究人员转向特征空间,通过高维特征比较提高鲁棒性。这些方法利用深度神经网络提取特征,覆盖更广泛的局部感受野,减少对空间对齐的要求,并提高对噪声的容忍度。

根据构建特征空间中正常“模板”的区别,此类方法被分为构造分类面与特征距离度量方法。

### 2.2.1 基于构造分类面的方法

构造分类面,又称为深度一类分类方法,旨在利用深度神经网络构建更高质量的特征空间,并在此基础上建立分类边界,其主要框架如图 5 所示。




图5 深度一类分类模型<sup>[1]</sup>

Fig. 5 Deep One-Class Classification Model

具体而言,在训练阶段,通过神经网络提取正常图像的特征:

$$L(\theta) = \sum_{x \in X_{normal}} \|f_{\theta}(x) - x\|^2 \quad (1)$$

其中  $f_{\theta}(x)$  是网络对输入  $x$  的重构,  $X_{normal}$  是正常样本集,

$\theta$  是网络的参数。并通过优化让这些特征向量在特征空间中尽可能地分布紧凑,从而形成描述正常特征边界的分界面,这可以通过以下公式来表示:

$$\min_{R, c} R^2 \quad (2)$$

$$\text{s.t. } \|f_{\theta}(x) - c\|^2 \leq R^2, \forall x \in X_{normal}$$

其中,  $R$  是超球体的半径,  $c$  是超球体的中心,  $f_{\theta}(x)$  是正常样本  $x$  在特征空间的表示。在测试阶段,模型会提取待检测样本的特征,并将其映射到上述特征空间中,通过分界面  $c$  判断是否为异常。

传统的一类分类方法在处理大规模或高维数据时存在限制,如在复杂工业图像处理中表现不佳,且基于核的方法需要大量内存。深度学习能够有效提取高维工业图像数据中的区分性特征,自动学习抽象特征表示,因此在复杂数据处理上具有更强适应性和表现力。

#### 1) 传统一类分类方法

早期深度一类分类方法分两阶段使用深度学习与传统一类分类方法,如 Sarah 等<sup>[93]</sup>先用无监督深度信念网络提取特征,再用这些特征训练一类支持向量机,具良好扩展性和计算效率。

Chalapathy 等<sup>[94]</sup>提升了复杂数据上的性能,结合深度网络特征提取能力与单类目标紧密包络,区别于自动编码器学习特征后再应用异常检测方法的混合方法。

Ruff 等<sup>[95]</sup>提出深度支持向量数据描述(Deep Support Vector Data Description, Deep SVDD)方法,目的是找到一个超球体仅包围训练集中的正常数据,并最小化超球体体积。训练中,落在超球体外的新数据点可认为是异常。Deep SVDD 另一关键优势是端到端训练,超球体学习与特征学习同时进行,提高系统效率和性能。




图6 Deep SVDD 原理示意图<sup>[1]</sup>

Fig. 6 Illustration of Deep SVDD

#### 2) 基于 Deep SVDD 方法的改进

然而不难发现,Deep SVDD 存在一定的局限性。首先,它对数据分布和特征表示高度依赖。其次,模型的超参数对性能影响很大,不当选择可能导致过拟合或欠拟合。最后,Deep SVDD 计算复杂度高且对标签数据需求较大。



Perera 等<sup>[96]</sup>提出了基于深度学习的单类迁移学习方法,该方法使用来自不相关任务的标记数据来进行特征学习。通过在选择的 CNN 上运行,产生描述性特征。OZA 等<sup>[97]</sup>则借鉴其他一类分类统计方法的一些启示,以区分的方式端到端训练 CNN 来学习一类问题的表示。而 Yi 等<sup>[98]</sup>提出的基于图块的支持向量数据描述 (Patch-based Support Vector Data Description, Patch SVDD) 的方法则解决了 Deep SVDD 无法定位异常区域的问题。该方法通过对不同图像块进行聚类,自动生成多个特征中心,实现了异常的检测和定位,其原理示意图如图 6 所示。

Liznerski 等<sup>[99]</sup>提出了全卷积数据描述 (Fully Convolutional Data Description, FCDD),该方法在映射过程中生成对异常检测的解释热图,解决了传统方法中解释性不足的问题。Wu 等<sup>[100]</sup>使用堆叠的卷积编码器来生成正常样本的低维高级特征,并训练一类分类器以保持特征的语义信息。

### 3) 自监督学习

为了在一类分类任务中实现性能的飞跃,自监督学习技术在一类分类任务中提供了高效的改进途径。它利用正常样本生成监督信号,帮助神经网络深入理解正常数据,从而增强模型的区分能力。

Golan 等<sup>[101]</sup>研究者基于 RotNet<sup>[102]</sup>概念发展了一种新策略,通过对输入数据施加几何变形训练网络识别转换。训练后的分类器对正常图像泛化良好,但对异常图像的转换预测不佳,适用于异常检测。Bergman 等<sup>[103]</sup>进一步扩展思路,结合 Deep SVDD,对正常样本进行几何转换并映射到特征子空间,形成超球体。测试阶段,超球体外的样本特征视为异常。

此外,研究界还探索了利用自监督方法生成负样本的策略来增强一类分类模型的判别力。Pourreza 等<sup>[104]</sup>利用 GAN 在训练初期生成的图像作为负样本,而 Li 等<sup>[105]</sup>则通过拼贴正常区域来构建负样本,用于训练监督分类的代理任务。

#### 2.2.2 基于特征距离度量的方法

深度一类分类技术致力于在特征空间中确定合适的子空间和判别边界,但这在处理复杂数据时非常困难。相比之下,特征距离度量方法通过在特征空间中找到“正常模板”并进行匹配,直接与待测样本的特征比较来进行异常检测。同时,仅使用正样本训练的特征提取器往往无法识别缺陷特征,因此研究者倾向于使用预训练模型,这些模型在广泛数据集上训练,具备强大的特征表征能力。

具体来说,特征距离度量方法又可以细分为孪生网络架构、深度统计模型、基于流模型的方法与教师-学生架构。

##### 1) 孪生网络架构

孪生网络架构通过一个一致的特征提取网络将多个图像映射到特征空间,通过比较待测图像的特征与正常模板来识别异常,其主要框架如图 7 所示。Napoleatano 等<sup>[106]</sup>提出了基于自相似度的异常检测方法,当样本与正常样本的最小距离

超过阈值时判定为异常。Cohen 等<sup>[107]</sup>提出了一种新的异常分割方法,称为语义金字塔异常检测 (Semantic Pyramid Anomaly Detection, SPADE)。该方法通过多分辨率特征金字塔对异常图像与正常图像进行对齐,不需要在图像上进行训练。




图7 孪生网络架构

Fig. 7 Frameworks Based on Feature Similarity

相比于 SPADE,其他方法可能更侧重于局部图像块之间的特征相似性和几何关系。如 Tsai 等<sup>[108]</sup>提出了基于多尺度图像块的表示学习方法,从正常图像中提取关键特征,考虑相邻图像块的相对特征相似性,以便更好地学习几何关系。而 Lee 等<sup>[109]</sup>通过耦合的超球体结构,提高了正常特征的密度,从而使得异常特征可以被清晰地区分。

##### 2) 深度统计模型

孪生网络架构的方法虽能取得不错的分类效果,但其对大量正常样本的需求和高训练成本是限制因素。为减少开销,基于深度统计模型的方法通过对正常样本特征进行概率分布建模,避免了庞大样本库的需求,其主要框架如图 8 所示。

Rippel 等<sup>[110]</sup>通过拟合一个多变量高斯分布到仅使用正常数据在 ImageNet<sup>[111]</sup>上训练的分类网络的深度特征表示上,来建立对正常性的模型。




图8 深度统计模型

Fig. 8 Deep Statistical Model

Defard 等<sup>[112]</sup>将多元高斯分布建模于图像块粒度,提出 PaDiM (Pattern Discovery and Mining) 框架实现像素级分割。PaDiM 利用预训练 CNN 进行补丁嵌入,使用多元高斯分布获得正常类别概率表示。相比 SPADE<sup>[107]</sup>,PaDiM 在处理大规模数据集时优势显著。

在 PaDiM 的基础上, Roth 等<sup>[113]</sup>提出了一种名为 PatchCore 的方法,使用名义 (非缺陷) 补丁特征的记忆库,在保持竞争性推理时间的同时,实现了先进的检测和定位性能。与 PaDiM 相比, PatchCore 在大规模数据集上表现更加出色。Liu 等<sup>[114]</sup>通过对比学习实现无监督异常检测的连续学习能力,并结合 Segment Anything Model (SAM) 改进了提示学习和异常分割结果。

近年来还有许多新的方法提出。Bac 等<sup>[115]</sup>通过结合位置和邻域信息,利用多层感知机网络建模正常特征分布,实现工业图像的异常检测。

### 3) 基于流模型的方法

归一化流(Normalizing Flow, NF)<sup>[116]</sup>模型是一种深度生成模型,它基于概率流理论,能够捕捉数据分布的复杂性。其核心思想是通过一系列连续可微的变换将一个简单的分布变换为复杂的数据分布,通过训练最小化负对数似然,即:

$$L = - \sum_{i=n-1}^N \log p(x_n) \quad (3)$$

Rudolph 等<sup>[117]</sup>首先引入 NF 模型,通过多尺度特征提取器使 NF 在处理高维图像数据时分配有意义的似然值,开发评分函数进行像素级定位,无须大量训练样本。Rudolph 等<sup>[118]</sup>还介绍 CS-Flow(Cross-Scale-Flows)用于图像级缺陷检测,联合处理不同尺度特征图,利用归一化流为输入样本分配有意义的似然值,实现高效图像级缺陷检测。

近年来,基于流模型的方法在工业缺陷检测领域崛起。Wang 等<sup>[119]</sup>通过整合对比学习,利用多种代理任务微调网络增强 2D-Flow 框架,使网络从自生成标签中学习更精确映射关系。Zhou 等<sup>[120]</sup>通过不对称平行流和融合流,实现多尺度感知,用于无监督异常检测和定位。

### 4) 教师 - 学生架构

另一种思路是通过“教师-学生训练方法”,通常是指在深度学习中的一种知识蒸馏技术,其中一个已经充分训练且表现良好的模型(教师)指导另一个待训练或较简单的模型(学生)的学习过程,设  $p_F$  和  $p_s$  分别为教师网络和学生网络的输出概率分布,则知识蒸馏的损失函数可以表示为:

$$L_{distill} = \sum_i p_F(i) \log p_s(i) \quad (4)$$

其主要框架如图 9 所示。该方法假设学生网络在缺陷表达上与教师网络存在较大回归误差,当学生网络无法准确复制教师网络对正常样本的表达时,通常表明样本中存在异常,其主要框架如图 10 所示。




图9 知识蒸馏方法

Fig. 9 Knowledge Distillation Method

教师学生模型首次提出是在 2020 年, Bergmann 等<sup>[121]</sup>提出了一种强大的学生-教师框架,其中教师网络在大量自然图像的补丁数据集上进行了预训练,学生网络则被训练来回归教师网络的输出。Wang 等<sup>[122]</sup>用自监督训练的教师网络学习更优特征,并用多学生网络增强异常检测性能,提高

准确性和鲁棒性。Salehi 等<sup>[123]</sup>将 ImageNet<sup>[111]</sup>特征蒸馏到简单克隆网络,通过专家和克隆网络中间激活值差异检测定位异常。




图10 教师-学生架构

Fig. 10 Teacher-Student Architecture

Wang 等<sup>[124]</sup>在前文基础上将多尺度特征匹配策略集成到框架中,使学生网络从特征金字塔中获得多层次知识的混合。但因训练中无异常样本约束,无法保证 S-T 网络间异常样本特征总不同。鉴于此, Zhang 等<sup>[125]</sup>通过合成损坏正常图像增强对异常数据约束,并自适应融合多级特征,显著提升性能。然而,当学生网络与教师网络结构相似时,可能面对训练分布外数据表现不佳。因此, Rudolph 等<sup>[126]</sup>提出不对称师生网络架构,通过高度不对称网络作为学生-教师对来避免非期望泛化,并引入作为教师双射规范化流改进学生-教师网络。

以往研究中,使用相似架构构建师生模型阻碍异常表征多样性。为解决此问题,研究者寻觅新方向,反向蒸馏是典型。Deng 等<sup>[127]</sup>提出新的教师学生模型,由教师编码器和学生解码器组成,引入简单有效的反向蒸馏范式。学生网络不直接接收原始图像,而以教师模型单类嵌入作为输入和目标,还原教师多尺度表征。Nguyen 等<sup>[128]</sup>对反向知识蒸馏进行了改进,通过结合多任务学习和反向蒸馏,以提高检测精度和效率。其主要创新包括特征紧凑任务和异常信号抑制任务,这些任务共同优化学生模型的特征表示,从而实现高精度和低延迟的异常检测。




图11 反向蒸馏方法

Fig. 11 Reverse Distillation Method

### 2.2.3 其他

除了上述方法之外,近年来还有一些新颖的方法也值得关注, Bergmann 等<sup>[129]</sup>提出了一种结合结构和逻辑异常检测的算法。该算法不仅检查受限区域,还学习全局一致表示。此外,他们还提供了一个新数据集,均匀覆盖了结构和逻辑异常。而 You 等<sup>[130]</sup>在工业缺陷检测中利用 Transformer 模型

重构预训练特征,使得重构异常特征变得更加困难,从而提  
高异常检测的效果。

表2 工业缺陷检测无监督深度学习方法评价

Tab. 2 Unsupervised Deep Learning Methods for Industrial Defect Detection

级别	类别	优点	局限性
像素	基于 AE 方法	实现简单直观	输出模糊,可能重建异常
	基于 VAE 方法	可以构建更好的潜在空间	重建的图像通常是模糊的
	基于 GAN 方法	GAN 很好地增强了图像重建的能力	训练成本高,生成器可能会不稳定,从而导致图像中正常区域的生成效果较差
	基于 Transformer 方法	捕获图像中的长期依赖关系,有助于理解内容	需要大量的数据进行训练,并且计算成本很高,尤其是在大图像的情况下
特征	深度一类分类	清晰地划分正常和异常样本之间的界限	当异常检测任务之间的相似性高时,性能是一般的
	孪生网络架构	充分利用预训练模型的能力	训练成本高
	深度统计模型	对正常样本特征的概率分布进行建模,避免了建立大型正态样本数据库	对模型结构和超参数的选择敏感
	流模型	较强的泛化能力和可解释性	对复杂缺陷的检测能力较差,缺乏专业的工业缺陷流模型
	教师-学生架构	充分利用预先训练好的模型,具有很强的灵活性和适应性	过于依赖于预训练模型,并存在诸如过渡泛化和正常遗忘等问题

最后,随着大语言模型的兴起,Gu 等<sup>[131]</sup>介绍了 AnomalyGPT,一种利用大型视觉-语言模型进行工业异常检测的方法。AnomalyGPT 通过模拟异常图像生成训练数据,并使用图像解码器提供细粒度语义。

如表 2 所示,本文总结了各类无监督学习方法的优缺点。

### 3 公开数据集与评价指标

#### 3.1 数据集

数据集是工业缺陷检测核心基础,常用于工业缺陷检测研究的数据集如表 3 所示,大部分数据集如 MVTec AD<sup>[132]</sup>常用于无监督学习。另一些常用于有监督学习的数据集也用于无监督学习,如 KolektorSDD<sup>[133]</sup>。

这些数据集提供了丰富的样本和多样的缺陷类型,推动了工业缺陷检测技术发展。

#### 3.2 评价标准

##### 3.2.1 AUROC

受试者工作特征曲线下面积(Area Under the Receiver Operating Characteristic curve, AUROC)是一个用于评估分类模型性能的统计指标,取值范围是[0,1],其中 1 表示完美的分类能力,0.5 表示没有分类能力,相当于随机猜测。它通过绘制真正率和假正率在不同阈值设置下的关系来构建受试者工作特征曲线, AUROC 值就是这条曲线下的面积。

##### 3.2.2 PRO

PRO(Per-Region Overlap)是一个用于评估异常定位性能的指标。PRO 是通过计算预测的异常区域与实际异常区域的重叠程度来评估模型的定位精度。它首先将定位的缺陷结果和真实的标注按连通域划分为多个区域,然后计算每个区域中预测结果和真值的交集,并将这些交集除以真值区域的大小,最后对所有区域的结果进行加权平均,得到 PRO 值。

##### 3.2.3 IoU

交并比(Intersection of Union, IoU),用于评价两个像素区域的重合情况。IoU 可以反映模型对于目标位置的预测精度,是一个介于 0 到 1 之间的值,用于衡量两个区域重叠的程度,通常为两区域交集面积与并集面积之比。

##### 3.2.4 FPS

帧率(Frames Per Second, FPS)在深度学习领域是衡量模型性能的重要指标之一。它表示模型每秒可以处理的帧数,通常用于评估模型的实时处理能力,特别是在目标检测和视频处理任务中。

##### 3.2.5 小结

AUROC、PRO、IoU 和 FPS 是评估缺陷检测模型性能的重要工具。它们提供了从不同角度评价模型性能的方法,对于开发和优化缺陷检测算法至关重要。



以 MvTec-AD 数据集为例, 表 4 展示了一些较为经典的方法的运行结果统计。

表3 工业缺陷检测常用的公开数据集

Tab. 3 Common Open Datasets for Industrial Defect Detection

名称	地址	简介
NanoTWICE <sup>[134]</sup>	<a href="http://www.mi.imati.cnr.it/ettore/NanoTWICE">http://www.mi.imati.cnr.it/ettore/NanoTWICE</a>	45 张图像, 非周期性连续纹理, 缺陷大小不一
MVTec AD <sup>[132]</sup>	<a href="https://www.mvtec.com/company/research/datasets/mvtec-ad">https://www.mvtec.com/company/research/datasets/mvtec-ad</a>	15 个类别, 每个类别约有 240 张正常图像和 100 张缺陷图像, 异常样本包含各种缺陷
BTAD <sup>[135]</sup>	<a href="http://avires.dimi.uniud.it/papers/btad/btad.zip">http://avires.dimi.uniud.it/papers/btad/btad.zip</a>	2830 张图像, 包括 3 种工业产品, 展示了表面和结构缺陷
Fabric dataset <sup>[136]</sup>	<a href="https://ytngan.wordpress.com/codes">https://ytngan.wordpress.com/codes</a>	3 种织物图像, 每种各有 25 张无缺陷和 25 张有缺陷的图像, 5 种缺陷类型
Textured dataset <sup>[137]</sup>	<a href="https://www.mvtec.com/company/research/publications">https://www.mvtec.com/company/research/publications</a>	两种编织织物纹理, 均为单通道灰度图像
RSDDs <sup>[138]</sup>	<a href="https://github.com/neu-rail-rsdds/rsdds">https://github.com/neu-rail-rsdds/rsdds</a>	在真实铁路轨道上收集, 包括 113 张二维彩色左图像与相应的深度图像
MT Defect <sup>[139]</sup>	<a href="https://github.com/abin24/Magnetic-tile-defect-datasets">https://github.com/abin24/Magnetic-tile-defect-datasets</a>	1344 张图像, 在多种光照条件下采集, 包含 6 种缺陷
AITEX <sup>[140]</sup>	<a href="https://aistudio.baidu.com/datasetdetail/90062">https://aistudio.baidu.com/datasetdetail/90062</a>	245 张图像, 7 种织物结构类别, 每一类包含 20 个无缺陷样本
KolektorSDD <sup>[133]</sup>	<a href="https://www.vicos.si/resources/kolektorsdd">https://www.vicos.si/resources/kolektorsdd</a>	电子换向器图像, 包含 348 张无缺陷图片以及 52 张有缺陷图片
KolektorSDD2 <sup>[141]</sup>	<a href="https://www.vicos.si/resources/kolektorsdd2">https://www.vicos.si/resources/kolektorsdd2</a>	356 张缺陷图像与 2979 张正常图像
VisA <sup>[142]</sup>	<a href="https://amazon-visual-anomaly.s3.us-west-2.amazonaws.com/VisA_20220922.tar">https://amazon-visual-anomaly.s3.us-west-2.amazonaws.com/VisA_20220922.tar</a>	12 种对象, 其中 9621 张是正常样本, 1200 张是异常样本
MVTec LOCO AD <sup>[129]</sup>	<a href="https://www.mvtec.com/company/research/datasets/mvtec-loco">https://www.mvtec.com/company/research/datasets/mvtec-loco</a>	5 个类别, 2076 张正常样本, 1568 张异常样本, 包括结构异常和逻辑异常

表4 模型运行信息统计

Tab. 4 Model Operation Information Statistics

模型	AUROC	PRO	FPS
EfficientAD <sup>[143]</sup>	96.8	96.5	614
CPR-faster <sup>[144]</sup>	99.0	97.3	478
CPR-fast <sup>[144]</sup>	99.2	97.7	245
CPR <sup>[144]</sup>	99.2	97.8	113
CDO <sup>[145]</sup>	98.7	96.5	79.6
CFLOW-AD <sup>[146]</sup>	98.6	94.6	27
PatchCore <sup>[113]</sup>	98.2	93.5	5.8

## 4 总结与展望

### 4.1 总结

在工业缺陷检测领域, 无监督深度学习方法来取得了显著进展。这些方法通过自动学习复杂特征、减少人工干预、实时处理数据、适应新缺陷等, 提升了检测的精确度和效率, 并推动了工业生产的智能化和自动化。然而, 该领域

仍面临一些挑战。如现有数据集通常局限于局部结构异常而忽视了对逻辑异常的处理; 现有数据集往往背景类型单一, 缺陷种类有限, 无法全面模拟实际工业场景; 某些情况下, 缺陷的定义可能因不同的客户需求或质量标准而异, 这使得检测标准难以统一, 从而增加了检测系统的复杂性; 对于不同工厂或不同产品线之间, 检测系统的直接迁移通常效果不佳, 如何在新环境下快速适应或在多种场景中实现有效迁移学习仍是研究的重点。

### 4.2 展望

1) Transformer 的应用。Transformer 架构因其全局关系建模能力而受到关注, 但对计算资源的依赖较高。当前, 学术界和工业界正致力于开发高效的 Transformer 模型, 并探索其在小型数据集上的应用。尽管目前 Transformer 在工业缺陷检测中的应用较少, 但已初步展现出潜在价值。

2) 多模态数据融合: 通过融合多种传感器数据 (如视觉、红外、超声波等), 未来的检测系统可以实现更加全面和准

确的缺陷检测。这种多模态数据融合将增强系统的鲁棒性，适应复杂的工业环境。

3) 智能化工厂与自动化检测：随着工业 4.0 的发展，缺陷检测将更加紧密地与自动化生产线集成。全自动化的缺陷检测与反馈系统将提高生产效率，实现缺陷的快速修复和生产线的动态调整。

### 参考文献

- [1] 罗东亮,蔡雨萱,杨子豪,等.工业缺陷检测深度学习综述[J]. 中国科学:信息科学,2022,52(6): 1002-1039. (LUO D L, CAI Y X, YANG Z H, et al. Survey on industrial defect detection with deep learning[J]. J. Sci. Sin. Inf, 2022, 52(6): 1002-1039.)
- [2] PANG G, SHEN C, CAO L, et al. Deep learning for anomaly detection: A review[J]. ACM Computing Survey, 2021, 54(2): 1-38.
- [3] COOK A A, Mısırlı G, FAN Z. Anomaly detection for IoT time-series data: A survey[J]. IEEE Internet of Things Journal, 2019, 7(7): 6481-6494.
- [4] CHANDOLA V, BANERJEE A, KUMAR V. Anomaly detection: A survey[J]. ACM Computing Surveys, 2009, 41(3): 1-58.
- [5] BULUSU S, KAILKHURA B, LI B, et al. Anomalous instance detection in deep learning: A survey[R]. Lawrence Livermore National Lab.(LLNL), Livermore, CA (United States), 2020, 8: 132330-132347.
- [6] ZHOU B, KHOSLA A, LAPEDRIZA A, et al. Learning deep features for discriminative localization[C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Washington, DC: IEEE Computer Society, 2016: 2921-2929.
- [7] ZHOU D H, WEI M H, SI X S. A survey on anomaly detection, life prediction and maintenance decision for industrial processes[J]. Acta Automatica Sinica, 2013, 39(6): 711-722.
- [8] CZIMMERMANN T, CIUTI G, MILAZZO M, et al. Visual-based defect detection and classification approaches for industrial applications—a survey[J]. Sensors, 2020, 20(5): 1459.
- [9] CHETVERIKOV D, HANBURY A. Finding defects in texture using regularity and local orientation[J]. Pattern Recognition, 2002, 35(10): 2165-2180.
- [10] DENG Y S, LUO A C, DAI M J. Building an automatic defect verification system using deep neural network for pcb defect classification[C]// Proceedings of the 2018 4th International Conference on Frontiers of Signal Processing. Piscataway: IEEE, 2018: 145-149.
- [11] SCHÖLKOPF B, WILLIAMSON R C, SMOLA A, et al. Support vector method for novelty detection[C]//Proceedings of the 1999 30th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc, 1999, 12: 582-588.
- [12] CHUNG H, PARK J, KEUM J, et al. Unsupervised anomaly detection using style distillation[J]. IEEE Access, 2020, 8: 221494-221502.
- [13] TAN D S, CHEN Y C, CHEN T P C, et al. Trustmae: A noise-resilient defect classification framework using memory-augmented auto-encoders with trust regions[C]// Proceedings of the 2021 IEEE/CVF Winter Conference on Applications of Computer Vision. Piscataway: IEEE, 2021: 276-285.
- [14] KIMURA D, CHAUDHURY S, NARITA M, et al. Adversarial discriminative attention for robust anomaly detection[C]// Proceedings of the 2020 IEEE/CVF Winter Conference on Applications of Computer Vision. Piscataway: IEEE, 2020: 2172-2181.
- [15] CHALAPATHY R, CHAWLA S. Deep learning for anomaly detection: A survey[EB/OL]. (2019-01-10) [2024-04-25]. <https://arxiv.org/abs/1901.03407>.
- [16] TAO X, HOU W, XU D. A survey of surface defect detection methods based on deep learning[J]. Acta Automatica Sinica, 2021, 47(5): 1017-1034.
- [17] EHRET T, DAVY A, MOREL J M, et al. Image anomalies: a review and synthesis of detection methods[J]. Journal of Mathematical Imaging and Vision, 2019, 61: 710-743.
- [18] YANG J, XU R, QI Z, et al. Visual anomaly detection for images: A systematic survey[J]. Procedia computer science, 2022, 199: 471-478.
- [19] RUFF L, KAUFFMANN J R, VANDERMEULEN R A, et al. A unifying review of deep and shallow anomaly detection[J]. Proceedings of the IEEE, 2021, 109(5): 756-795.
- [20] MOHAMMADI B, FATHY M, SABOKROU M. Image/video deep anomaly detection: A survey[EB/OL]. (2021-03-02) [2024-04-25]. <https://arxiv.org/abs/2103.01739>.
- [21] SABERIRONAGHI A, REN J, EL-GINDY M. Defect detection methods for industrial products using deep learning techniques: A review[J]. Algorithms, 2023, 16(2): 95.
- [22] CUI Y, LIU Z, LIAN S. A survey on unsupervised anomaly detection algorithms for industrial images[J]. IEEE Access, 2023, 11: 55297-55315.
- [23] DUTTA P, NAYAK R, PATI U C. Exploring Deep Learning-based Unsupervised Image Anomaly Detection and Localization Methods for Industrial Quality Assurance[C]// Proceedings of the 2024 1st International Conference on Cognitive, Green and Ubiquitous Computing. India: IEEE, 2024: 1-6.
- [24] HINTON G E, ZEMEL R S. Autoencoders, minimum description length and Helmholtz free energy[C]//Proceedings of the 1993 30th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc, 1993, 6.
- [25] KINGMA D P, WELING M. Auto-encoding variational bayes [EB/OL]. (2022-12-10) [2024-04-25].<https://arxiv.org/abs/1312.6114>.
- [26] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]//Proceedings of the 2014 30th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc, 2014, 27:2672 – 2680.
- [27] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[EB/OL]. (2023-08-02) [2024-04-25]. <https://arxiv.org/abs/1706.03762>.
- [28] KANG, G., GAO, S., YU, L., et al. Deep architecture for high-speed railway insulator surface defect detection: Denoising autoencoder with multitask learning[J]. IEEE Transactions on Instrumentation and Measurement, 2018, 68(8): 2679-2690.
- [29] YOUKACHEN S, RUCHANURUCKS M, PHATRAPOMNANT T, et al. Defect segmentation of hot-rolled steel strip surface by using convolutional auto-encoder and conventional image processing[C]// Proceedings of the 2019 10th International Conference of Information and Communication Technology for Embedded Systems. Bangkok, Thailand: IEEE, 2019: 1-5.
- [30] MEI S, WANG Y, WEN G. Automatic fabric defect detection with a multi-scale convolutional denoising autoencoder network model[J]. Sensors, 2018, 18(4): 1064.
- [31] YANG H, CHEN Y, SONG K, et al. Multiscale feature-clustering-based fully convolutional autoencoder for fast accurate visual inspection of texture surface defects[J]. IEEE Transactions on Automation Science and Engineering, 2019, 16(3): 1450-1467.
- [32] YANG J, SHI Y, QI Z. Dfr: Deep feature reconstruction for unsupervised anomaly segmentation[EB/OL]. (2020-12-13) [2024-04-25]. <https://arxiv.org/abs/2012.07122>.
- [33] GONG D, LIU L, LE V, et al. Memorizing normality to detect anomaly: Memory-augmented deep autoencoder for unsupervised anomaly detection[C]// Proceedings of the 2019 IEEE/CVF international conference on computer vision. COEX Convention Center in Seoul, South Korea: IEEE, 2019: 1705-1714..

- [34] YANG Y, XIANG S, ZHANG R. Improving unsupervised anomaly localization by applying multi-scale memories to autoencoders[EB/OL]. (2020-12-21) [2024-04-26]. <https://arxiv.org/abs/2012.11113>.
- [35] PARK H, NOH J, HAM B. Learning memory-guided normality for anomaly detection[C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 14372-14381.
- [36] WANG T, XU X, SHEN F, et al. A cognitive memory-augmented network for visual anomaly detection[J]. IEEE/CAA Journal of Automatica Sinica, 2021, 8(7): 1296-1307.
- [37] TAN D S, CHEN Y C, CHEN T P C, et al. Trustmae: A noise-resilient defect classification framework using memory-augmented auto-encoders with trust regions[C]// Proceedings of the 2021 IEEE/CVF winter conference on applications of computer vision. Virtual: IEEE, 2021: 276-285.
- [38] YAO H, YU W, WANG X. A feature memory rearrangement network for visual inspection of textured surface defects toward edge intelligent manufacturing[J]. IEEE Transactions on Automation Science and Engineering, 2022, 20(4): 2616-2635.
- [39] XING P, LI Z. Visual anomaly detection via partition memory bank module and error estimation[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023, 33(8): 3596-3607.
- [40] LIU W, CHANG H, MA B, et al. Diversity-measurable anomaly detection[C]// Proceedings of the 2023 IEEE/CVF conference on computer vision and pattern recognition. Vancouver Convention Center, Vancouver, Canada: IEEE, 2023: 12147-12156.
- [41] LI Z, LI N, JIANG K, et al. Superpixel Masking and Inpainting for Self-Supervised Anomaly Detection[C]// Proceedings of the 2020 British Machine Vision Conference. Virtual: British Machine Vision Association, 2020.
- [42] ZENG Y, FU J, CHAO H, et al. Learning pyramid-context encoder network for high-quality image inpainting[C]// Proceedings of the 2019 IEEE/CVF conference on computer vision and pattern recognition. Long Beach, CA, USA: IEEE, 2019: 1486-1494.
- [43] HUANG C, XU Q, WANG Y, et al. Self-supervised masking for unsupervised anomaly detection and localization[J]. IEEE Transactions on Multimedia, 2022, 25: 4426-4438.
- [44] YE F, HUANG C, CAO J, et al. Attribute restoration framework for anomaly detection[J]. IEEE Transactions on Multimedia, 2020, 24: 116-127.
- [45] COLLIN A S, DE VLEESCHOUWER C. Improved anomaly detection by training an autoencoder with skip connections on images corrupted with stain-shaped noise[C]// Proceedings of the 2020 25th International Conference on Pattern Recognition. MiCo Milano Congress Center, Milan, Italy: IEEE, 2021: 7915-7922.
- [46] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]// Proceedings of the 2015 Medical image computing and computer-assisted intervention. Munich, Germany: Springer International Publishing, 2015: 234-241.
- [47] ZAVRTANIK V, KRISTAN M, SKOČAJ D. Draem-a discriminatively trained reconstruction embedding for surface anomaly detection[C]// Proceedings of the 2021 IEEE/CVF international conference on computer vision. Virtual: IEEE, 2021: 8330-8339.
- [48] SONG K, YANG H, YIN Z. Anomaly composition and decomposition network for accurate visual inspection of texture defects[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-14.
- [49] BAUER A, NAKAJIMA S, MVLLER K R. Self-supervised training with autoencoders for visual anomaly detection[EB/OL]. (2024-01-24) [2024-04-26]. <https://arxiv.org/abs/2206.11723>.
- [50] ZAVRTANIK V, KRISTAN M, SKOČAJ D. Dsr - a dual subspace re-projection network for surface anomaly detection[C]// Proceedings of the 2022 European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 539-554.
- [51] XING P, SUN Y, LI Z. Self-supervised guided segmentation framework for unsupervised anomaly detection[EB/OL]. (2022-09-26) [2024-04-26]. <https://arxiv.org/abs/2209.12440>.
- [52] MOUSAKHAN A, BROX T, TAYYUB J. Anomaly detection with conditioned denoising diffusion models[EB/OL]. (2023-05-25) [2024-04-26]. <https://arxiv.org/abs/2305.15956>.
- [53] CHUNG H, PARK J, KEUM J, et al. Unsupervised anomaly detection using style distillation[J]. IEEE Access, 2020, 8: 221494-221502.
- [54] DEHAENE D, FRIGO O, COMBEXELLE S, et al. Iterative energy-based projection on a normal data manifold for anomaly localization[EB/OL]. (2020-02-10) [2024-04-26]. <https://arxiv.org/abs/2002.03734>.
- [55] ABATI D, PORRELLO A, CALDERARA S, et al. Latent space autoregression for novelty detection[C]// Proceedings of the 2019 IEEE/CVF conference on computer vision and pattern recognition. Long Beach, CA, USA: IEEE, 2019: 481-490.
- [56] XIE X, LI X, WANG B, et al. Unsupervised abnormal detection using VAE with memory[J]. Soft Computing, 2022, 26(13): 6219-6231.
- [57] LIU W, LI R, ZHENG M, et al. Towards visually explaining variational autoencoders[C]// Proceedings of the 2020 IEEE/CVF conference on computer vision and pattern recognition. Seattle, WA, USA: IEEE, 2020: 8642-8651.
- [58] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-cam: Visual explanations from deep networks via gradient-based localization[C]// Proceedings of the 2017 IEEE international conference on computer vision. Venice, Italy: IEEE, 2017: 618-626.
- [59] ZHOU Q, MEI J, ZHANG Q, et al. Semi-supervised fabric defect detection based on image reconstruction and density estimation[J]. Textile Research Journal, 2021, 91(9/10): 962-972.
- [60] SCHLEGL T, SEEBÖCK P, WALDSTEIN S M, et al. Unsupervised anomaly detection with generative adversarial networks to guide marker discovery[C]// Proceedings of the 2017 International conference on information processing in medical imaging. Cham: Springer International Publishing, 2017: 146-157.
- [61] MURASE H, FUKUMIZU K. Algan: Anomaly detection by generating pseudo anomalous data via latent variables[J]. IEEE Access, 2022, 10: 44259-44270.
- [62] ZENATI H, FOO C S, LECOUAT B, et al. Efficient gan-based anomaly detection[EB/OL]. (2019-05-01) [2024-05-20]. <https://arxiv.org/abs/1802.06222>.
- [63] SABOKROU M, KHALOOEI M, FATHY M, et al. Adversarially learned one-class classifier for novelty detection[C]// Proceedings of the 2018 IEEE conference on computer vision and pattern recognition. Salt Lake City, UT, USA: IEEE, 2018: 3379-3388.
- [64] SCHLEGL T, SEEBÖCK P, WALDSTEIN S M, et al. f-AnoGAN: Fast unsupervised anomaly detection with generative adversarial networks[J]. Medical image analysis, 2019, 54: 30-44.
- [65] BAUR C, WIESTLER B, ALBARQOUNI S, et al. Deep autoencoding models for unsupervised anomaly segmentation in brain MR images[C]// Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries: 4th International Workshop, BrainLes 2018.. Granada, Spain: Springer International Publishing, 2019: 161-169.
- [66] AKÇAY S, ATAPOUR-ABARGHOUEI A, BRECKON T P. Skip-ganomaly: Skip connected and adversarially trained encoder-decoder anomaly detection[C]// Proceedings of the 2019 International Joint Conference on Neural Networks. Budapest, Hungary: IEEE, 2019: 1-8.
- [67] ZAHEER M Z, LEE J H, MAHMOOD A, et al. Stabilizing adversarially learned one-class novelty detection using pseudo anomalies[J]. IEEE Transactions on Image Processing, 2022, 31: 5963-5975.



- [68] LIANG Y, ZHANG J, ZHAO S, et al. Omni-frequency channel-selection representations for unsupervised anomaly detection[EB/OL]. (2023-07-03) [2024-05-20]. <https://arxiv.org/abs/2203.00259>.
- [69] BERTHELOT D, SCHUMM T, METZ L. BEGAN: Boundary Equilibrium Generative Adversarial Networks[EB/OL]. (2017-05-31) [2024-05-20]. <https://arxiv.org/abs/1703.10717>.
- [70] TANG T W, KUO W H, LAN J H, et al. Anomaly detection neural network with dual auto-encoders GAN and its industrial inspection applications[J]. *Sensors*, 2020, 20(12): 3336.
- [71] YANG H, ZHOU Q, SONG K, et al. An anomaly feature-editing-based adversarial network for texture defect visual inspection[J]. *IEEE Transactions on Industrial Informatics*, 2020, 17(3): 2220-2230.
- [72] AKCAY S, ATAPOUR-ABARGHOUEI A, BRECKON T P. Ganomaly: Semi-supervised anomaly detection via adversarial training[C]// *Proceedings of the 2018 Computer Vision - ACCV 2018: 14th Asian Conference on Computer Vision*. Perth, Australia: Springer International Publishing, 2019: 622-637.
- [73] KOMOTO K, AIZAWA H, KATO K. Consistency ensured bi-directional gan for anomaly detection[C]// *Proceedings of the 2020 Frontiers of Computer Vision: 26th International Workshop, IW-FCV 2020*. Ibusuki, Kagoshima, Japan: Springer Singapore, 2020: 236-247.
- [74] ZHOU K, XIAO Y, YANG J, et al. Encoding structure-texture relation with p-net for anomaly detection in retinal images[C]// *Proceedings of the 2020 Computer Vision - ECCV 2020: 16th European Conference*. Glasgow, UK: Springer International Publishing, 2020: 360-377.
- [75] HONG E, CHOE Y. Latent feature decentralization loss for one-class anomaly detection[J]. *IEEE Access*, 2020, 8: 165658-165669.
- [76] VENKATARAMANAN S, PENG K C, SINGH R V, et al. Attention guided anomaly localization in images[C]// *Proceedings of the 2020 European Conference on Computer Vision*. Cham: Springer International Publishing, 2020: 485-503.
- [77] PIDHORSKYI S, ALMOHSEN R, DORETTO G. Generative probabilistic novelty detection with adversarial autoencoders[C]// *Proceedings of the 2018 30th International Conference on Neural Information Processing Systems*. Red Hook, NY: Curran Associates Inc, 2018, 31.
- [78] PERERA P, NALLAPATI R, XIANG B. Ocgan: One-class novelty detection using gans with constrained latent representations[C]// *Proceedings of the 2019 IEEE/CVF conference on computer vision and pattern recognition*. Long Beach, CA, USA: IEEE, 2019: 2898-2906.
- [79] HOU J, ZHANG Y, ZHONG Q, et al. Divide-and-assemble: Learning block-wise memory for unsupervised anomaly detection[C]// *Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision*. Virtual: IEEE, 2021: 8791-8800.
- [80] SALEHI M, EFTEKHAR A, SADJADI N, et al. Puzzle-ae: Novelty detection in images through solving puzzles[EB/OL]. (2022-02-10) [2024-05-20]. <https://arxiv.org/abs/2008.12959>.
- [81] YAN X, ZHANG H, XU X, et al. Learning semantic context from normal samples for unsupervised anomaly detection[C]// *Proceedings of the 2021 AAAI conference on artificial intelligence*. Virtual: AAAI, 2021, 35(4): 3110-3118.
- [82] PIRNAY J, CHAI K. Inpainting transformer for anomaly detection[C]// *Proceedings of the 2022 International Conference on Image Analysis and Processing*. Cham: Springer International Publishing, 2022: 394-406.
- [83] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[EB/OL]. (2021-06-03) [2024-05-20]. <https://arxiv.org/abs/2010.11929>.
- [84] MISHRA P, VERK R, FORNASIER D, et al. VT-ADL: A vision transformer network for image anomaly detection and localization[C]// *Proceedings of the 2021 IEEE 30th International Symposium on Industrial Electronics*. Kyoto, Japan: IEEE, 2021: 01-06.
- [85] LEE Y, KANG P. AnoViT: Unsupervised anomaly detection and localization with vision transformer-based encoder-decoder[J]. *IEEE Access*, 2022, 10: 46717-46724.
- [86] DE NARDIN A, MISHRA P, FORESTI G L, et al. Masked transformer for image anomaly localization[J]. *International Journal of Neural Systems*, 2022, 32(07): 2250030.
- [87] YOU Z, CUI L, SHEN Y, et al. A unified model for multi-class anomaly detection[C]// *Proceedings of the 2022 30th International Conference on Neural Information Processing Systems*. Red Hook, NY: Curran Associates Inc, 2022, 35: 4571-4584.
- [88] JIANG J, ZHU J, BILAL M, et al. Masked swin transformer unet for industrial anomaly detection[J]. *IEEE Transactions on Industrial Informatics*, 2022, 19(2): 2200-2209.
- [89] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]// *Proceedings of the 2021 IEEE/CVF international conference on computer vision*. Montreal, QC, Canada: IEEE, 2021: 10012-10022.
- [90] YAO H, LUO W, YU W. Visual Anomaly Detection via Dual-Attention Transformer and Discriminative Flow[EB/OL]. (2023-03-31) [2024-05-25]. <https://arxiv.org/abs/2303.17882>.
- [91] ZHANG M, TIAN X. Transformer architecture based on mutual attention for image-anomaly detection[J]. *Virtual Reality & Intelligent Hardware*, 2023, 5(1): 57-67.
- [92] XIAO S, ZHANG T, XU Z, et al. Anomaly detection of hyperspectral images based on transformer with spatial - spectral dual-window mask[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2023, 16: 1414-1426.
- [93] ERFANI S M, RAJASEGARAR S, KARUNASEKERA S, et al. High-dimensional and large-scale anomaly detection using a linear one-class SVM with deep learning[J]. *Pattern Recognition*, 2016, 58: 121-134.
- [94] CHALAPATHY R, MENON A K, CHAWLA S. Anomaly detection using one-class neural networks[EB/OL]. (2019-06-11) [2024-05-25]. <https://arxiv.org/abs/1802.06360>.
- [95] RUFF L, VANDERMEULEN R, GOERNITZ N, et al. Deep one-class classification[C]// *Proceedings of the 2018 International conference on machine learning*. Stockholm, Sweden: PMLR, 2018: 4393-4402.
- [96] PERERA P, PATEL V M. Learning deep features for one-class classification[J]. *IEEE Transactions on Image Processing*, 2019, 28(11): 5450-5463.
- [97] OZA P, PATEL V M. One-class convolutional neural network[J]. *IEEE Signal Processing Letters*, 2018, 26(2): 277-281.
- [98] YI J, YOON S. Patch svdd: Patch-level svdd for anomaly detection and segmentation[C]// *Proceedings of the 2020 Asian conference on computer vision*. Kyoto, Japan: Springer International Publishing, 2020: 375-390.
- [99] LIZNERSKI P, RUFF L, VANDERMEULEN R A, et al. Explainable deep one-class classification[EB/OL]. (2021-05-18) [2024-05-25]. <https://arxiv.org/abs/2007.01760>.
- [100] WU P, LIU J, SHEN F. A deep one-class neural network for anomalous event detection in complex scenes[J]. *IEEE transactions on neural networks and learning systems*, 2019, 31(7): 2609-2622.
- [101] GOLAN I, EI-YANIV R. Deep anomaly detection using geometric transformations[C]// *Proceedings of the 2018 30th International Conference on Neural Information Processing Systems*. Red Hook, NY: Curran Associates Inc, 2018, 31: 9781 - 9791.
- [102] GIDARIS S, SINGH P, KOMODAKIS N. Unsupervised representation learning by predicting image rotations[EB/OL]. (2018-05-21) [2024-05-25]. <https://arxiv.org/abs/1803.07728>.

- [103] BERGMAN L, HOSHEN Y. Classification-based anomaly detection for general data[EB/OL]. (2020-05-05) [2024-05-25].<https://arxiv.org/abs/2005.02359>.
- [104] POURREZA M, MOHAMMADI B, KHAKI M, et al. G2d: Generate to detect anomaly[C]// Proceedings of the 2021 IEEE/CVF Winter Conference on Applications of Computer Vision. Waikoloa, HI, USA: IEEE, 2021: 2003-2012.
- [105] LI C L, SOHN K, YOON J, et al. Cutpaste: Self-supervised learning for anomaly detection and localization[C]// Proceedings of the 2021 IEEE/CVF conference on computer vision and pattern recognition. Nashville, TN, USA: IEEE, 2021: 9664-9674.
- [106] NAPOLETANO P, PICCOLI F, SCHETTINI R. Anomaly detection in nanofibrous materials by CNN-based self-similarity[J]. *Sensors*, 2018, 18(1): 209.
- [107] COHEN N, HOSHEN Y. Sub-image anomaly detection with deep pyramid correspondences[EB/OL]. (2021-02-03) [2024-06-06].<https://arxiv.org/abs/2005.02357>.
- [108] TSAI C C, WU T H, LAI S H. Multi-scale patch-based representation learning for image anomaly detection and segmentation[C]// Proceedings of the 2022 IEEE/CVF winter conference on applications of computer vision. Waikoloa, HI, USA: IEEE, 2022: 3992-4000.
- [109] LEE S, LEE S, SONG B C. Cfa: Coupled-hypersphere-based feature adaptation for target-oriented anomaly localization[J]. *IEEE Access*, 2022, 10: 78446-78454.
- [110] RIPPEL O, MERTENS P, MERHOF D. Modeling the distribution of normal data in pre-trained deep features for anomaly detection[C]// Proceedings of the 2020 25th International Conference on Pattern Recognition. Milan, Italy: IEEE, 2021: 6726-6733.
- [111] DENG J, DONG W, SOCHER R, et al. Imagenet: A large-scale hierarchical image database[C]// Proceedings of the 2009 IEEE conference on computer vision and pattern recognition. Miami, FL, USA: IEEE, 2009: 248-255.
- [112] DEFARD T, SETKOV A, LOESCH A, et al. Padim: a patch distribution modeling framework for anomaly detection and localization[C]// Proceedings of the 2021 International Conference on Pattern Recognition. Cham: Springer International Publishing, 2021: 475-489.
- [113] ROTH K, PEMULA L, ZEPEDA J, et al. Towards total recall in industrial anomaly detection[C]// Proceedings of the 2022 IEEE/CVF conference on computer vision and pattern recognition. New Orleans, LA, USA: IEEE, 2022: 14318-14328.
- [114] LIU J, WU K, NIE Q, et al. Unsupervised Continual Anomaly Detection with Contrastively-Learned Prompt[C]// Proceedings of the 2024 AAAI Conference on Artificial Intelligence. Vancouver, Canada: AAAI, 2024, 38(4): 3639-3647.
- [115] BAE J, LEE J H, KIM S. PNI: Industrial anomaly detection using position and neighborhood information[C]// Proceedings of the 2023 IEEE/CVF International Conference on Computer Vision. Paris, France: IEEE, 2023: 6373-6383.
- [116] REZENDE D, MOHAMED S. Variational inference with normalizing flows[C]// Proceedings of the 2015 International conference on machine learning. Lille, France: ICML, 2015: 1530-1538.
- [117] RUDOLPH M, WANDT B, ROSENHAHN B. Same same but different: Semi-supervised defect detection with normalizing flows[C]// Proceedings of the 2021 IEEE/CVF winter conference on applications of computer vision. Waikoloa, HI, USA: IEEE, 2021: 1907-1916.
- [118] RUDOLPH M, WEHRBEIN T, ROSENHAHN B, et al. Fully convolutional cross-scale-flows for image-based defect detection[C]// Proceedings of the 2022 IEEE/CVF Winter Conference on Applications of Computer Vision. Waikoloa, HI, USA: IEEE, 2022: 1088-1097.
- [119] WANG S, LI Y, LUO H, et al. CL-flow: strengthening the normalizing flows by contrastive learning for better anomaly detection[C]// Proceedings of the 2024 International Conference on Image, Signal Processing, and Pattern Recognition. Tokyo, Japan: IEEE, 2024: 1486-1493.
- [120] ZHOU Y, XU X, SONG J, et al. Msflow: Multiscale flow-based framework for unsupervised anomaly detection[EB/OL]. (2023-08-29) [2024-06-06].<https://arxiv.org/abs/2308.15300>.
- [121] BERGMANN P, FAUSER M, SATTLEGER D, et al. Uninformed students: Student-teacher anomaly detection with discriminative latent embeddings[C]// Proceedings of the 2020 IEEE/CVF conference on computer vision and pattern recognition. Seattle, WA, USA: IEEE, 2020: 4183-4192.
- [122] XIAO Q, WANG J, LIN Y, et al. Unsupervised anomaly detection with distilled teacher-student network ensemble[J]. *Entropy*, 2021, 23(2): 201.
- [123] SALEHI M, SADJADI N, BASELIZADEH S, et al. Multiresolution knowledge distillation for anomaly detection[C]// Proceedings of the 2021 IEEE/CVF conference on computer vision and pattern recognition. Nashville, TN, USA: IEEE, 2021: 14902-14912.
- [124] WANG G, HAN S, DING E, et al. Student-teacher feature pyramid matching for anomaly detection[EB/OL]. (2021-10-28) [2024-06-06].<https://arxiv.org/abs/2103.04257>.
- [125] ZHANG X, LI S, LI X, et al. Destseg: Segmentation guided denoising student-teacher for anomaly detection[C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, BC, Canada: IEEE, 2023: 3914-3923.
- [126] RUDOLPH M, WEHRBEIN T, ROSENHAHN B, et al. Asymmetric student-teacher networks for industrial anomaly detection[C]// Proceedings of the 2023 IEEE/CVF winter conference on applications of computer vision. Waikoloa, HI, USA: IEEE, 2023: 2592-2602.
- [127] DENG H, LI X. Anomaly detection via reverse distillation from one-class embedding[C]// Proceedings of the 2022 IEEE/CVF conference on computer vision and pattern recognition. New Orleans, LA, USA: IEEE, 2022: 9737-9746.
- [128] TIEN T D, NGUYEN A T, TRAN N H, et al. Revisiting reverse distillation for anomaly detection[C]// Proceedings of the 2023 IEEE/CVF conference on computer vision and pattern recognition. Vancouver, BC, Canada: IEEE, 2023: 24511-24520.
- [129] BERGMANN P, BATZNER K, FAUSER M, et al. Beyond dents and scratches: Logical constraints in unsupervised anomaly detection and localization[J]. *International Journal of Computer Vision*, 2022, 130(4): 947-969.
- [130] YOU Z, YANG K, LUO W, et al. Adtr: Anomaly detection transformer with feature reconstruction[C]// Proceedings of the 2022 International Conference on Neural Information Processing. Cham: Springer International Publishing, 2022: 298-310.
- [131] GU Z, ZHU B, ZHU G, et al. Anomalygpt: Detecting industrial anomalies using large vision-language models[C]// Proceedings of the 2024 AAAI Conference on Artificial Intelligence. Vancouver, Canada: AAAI, 2024, 38(3): 1932-1940.
- [132] BERGMANN P., BATZNER K., FAUSER M., et al. The MVTec anomaly detection dataset: a comprehensive real-world dataset for unsupervised anomaly detection[J]. *International Journal of Computer Vision*, 2021, 129(4): 1038-1059.
- [133] TABERNIK D., ŠELA S., SKVARČ J., et al. Segmentation-based deep-learning approach for surface-defect detection[J]. *Journal of Intelligent Manufacturing*, 2020, 31(3): 759-776.
- [134] CARRERA D., MANGANINI F., BORACCHI G., et al. Defect detection in SEM images of nanofibrous materials[J]. *IEEE Transactions on Industrial Informatics*, 2016, 13(2): 551-561.

- [135] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows. Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [136] TSANG C. S., NGAN H. Y., PANG G. K. Fabric inspection based on the Elo rating method[J]. Pattern Recognition, 2016, 51: 378-394.
- [137] BERGMANN P., LÖWE S., FAUSER M., et al. Improving unsupervised defect segmentation by applying structural similarity to autoencoders[EB/OL]. (2019-02-01) [2024-08-25].<https://arxiv.org/abs/1807.02011>
- [138] GAN J., LI Q., WANG J., et al. A hierarchical extractor-based visual rail surface inspection system. IEEE Sensors Journal, 2017, 17(23), 7935-7944.
- [139] HUANG Y., QIU C., YUAN K. Surface defect saliency of magnetic tile. The Visual Computer, 2020, 36(1), 85-96.
- [140] SILVESTRE-BLANES J., ALBERO-ALBERO T., MIRALLES I., et al. A public fabric database for defect detection methods and results. Autex Res J, 2019, 19, 363 – 374.
- [141] BOŽIČ J., TABERNIK D., SKOČAJ D. Mixed supervision for surface-defect detection: From weakly to fully supervised learning[J]. Computers in Industry, 2021, 129: 103459.
- [142] ZOU Y., JEONG J., PEMULA L., et al. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation[C]// Proceedings of the 2022 European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 392-408.
- [143] BATZNER K., HECKLER L., KÖNIG R. Efficientad: Accurate visual anomaly detection at millisecond-level latencies[C]// Proceedings of the 2024 IEEE/CVF Winter Conference on Applications of Computer Vision. Waikoloa, HI, USA: IEEE, 2024: 128-138.
- [144] LI H, HU J, LI B, et al. Target before shooting: Accurate anomaly detection and localization under one millisecond via cascade patch retrieval[EB/OL]. (2023-08-23) [2024-08-25].<https://arxiv.org/abs/2308.06748>.
- [145] CAO Y, XU X, LIU Z, et al. Collaborative discrepancy optimization for reliable image anomaly localization[J]. IEEE Transactions on Industrial Informatics, 2023, 19(11): 10674-10683.
- [146] GUDOVSKIY D, ISHIZAKA S, KOZUKA K. Cflow-ad: Real-time unsupervised anomaly detection with localization via conditional normalizing flows[C]// Proceedings of the 2022 IEEE/CVF winter conference on applications of computer vision. Waikoloa, HI, USA: IEEE, 2022: 98-107.

**WANG Wenpeng**, born in 2001, M.S. candidate. His research interests include big data analysis and applications.

**QIN Yinchang**, born in 2000, M.S. candidate. His research interests include big data analysis and applications.

**SHI Wenxuan**, born in 1977, Ph.D., associate professor. His research interests include machine learning and blockchain.